Departamento de Ciência da Computação – UFSJ/DCOMP

MINERAÇÃO DE DADOS APLICADA À DINÂMICA DE PREÇOS NAS CEASAS

Pré-processamento, Granger, Efeito Dominó e protocolo de modelagem

Autores:

Arthur Henrique Moreira Santos
Gabriel da Silva Souza
Samuel de Souza Carvalho Almeida

Ciência da Computação – UFSJ/DCOMP

São João del-Rei – MG
2026

Sumário

Resumo **1**

1 Introdução **1**

1.1 Contextualização 1
1.2 Objetivos 2
1.2.1 Perguntas de pesquisa 2
1.2.2 Objetivo geral 2
1.2.3 Objetivos específicos 2
1.3 Trabalhos relacionados 3

2 Métodos **3**

2.1 Caracterização da base de dados 3
2.2 Visão geral do fluxo 4
2.3 Ambiente e reprodutibilidade 4
2.4 Política de retenção dos dados do crawler 6
2.5 Tipos de decisão sobre um registro 6
2.6 Seleção e consolidação das cotações 6
2.7 Normalização dos produtos 7
2.8 Tratamento das apresentações e unidades 7
2.9 Conversões inferidas 8
2.10 Exclusões e indicadores de qualidade 8
2.11 Estrutura e validação da saída 9
2.12 Construção das séries temporais 10
2.12.1 Recorte e critérios de entrada 10
2.12.2 Agregação, preenchimento e retornos 10
2.13 Teste de causalidade de Granger 11
2.13.1 Formação e qualificação dos pares 11
2.13.2 Diagnóstico de estacionariedade 11
2.13.3 Especificação, seleção de lags e significância 11
2.13.4 Validação e rastreabilidade 12
2.14 Caracterização do Efeito Dominó 12
2.14.1 Relações analisadas e definição de choque 12
2.14.2 Classificação dos eventos 13
2.14.3 Rastreabilidade e validação 14
2.15 Construção da base de modelagem 14
2.15.1 Unidade de análise, alvo e elegibilidade 15
2.15.2 Construção dos atributos 15
2.15.3 Separação entre preditores e auditoria 15
2.15.4 Protocolo de validação temporal 17

2.16 Treinamento, seleção e avaliação final 17
2.16.1 Escopo dos dados e separação das etapas 17
2.16.2 Validação da entrada 18
2.16.3 Preparação dos atributos dentro de cada treino 18
2.16.4 Baselines, classificadores e configurações 19
2.16.5 Ajuste nas validações e escolha do limiar 20
2.16.6 Métricas e dependência entre eventos 20
2.16.7 Saídas e rastreabilidade da seleção 21
2.16.8 Ajuste e avaliação final isolada 21

3 Resultados **22**
3.1 Resultados do teste de Granger 22
3.2 Resultados da caracterização do Efeito Dominó 22
3.3 Distribuição temporal para a modelagem 23

4 Discussão **23**
4.1 Interpretação das relações temporais 23
4.2 Suficiência e dependência das observações 24
4.3 Limitações e próxima etapa 24

Referências **26**

Resumo

Este trabalho investiga a dinâmica de preços de produtos agrícolas comercializados em diferentes Centrais de Abastecimento (CEASAs). A etapa atual concentra-se no Efeito Dominó, entendido como a possibilidade de movimentos de preço observados em um entreposto contribuírem para antecipar movimentos posteriores em outro. Os dados foram coletados por um *crawler* e organizados em um banco SQLite com mais de dois milhões de cotações. O fluxo executado até o momento compreende a preservação do banco bruto, o pré-processamento das cotações, a construção de séries temporais comparáveis, o teste de causalidade de Granger e a caracterização do Efeito Dominó. Na execução encadeada documentada, 2.388.316 registros brutos resultaram em 2.295.374 cotações no banco derivado, das quais 1.833.870 possuem preço comum em R$/kg. O recorte temporal carregou 175.160 cotações e produziu 252 pares candidatos entre mercados. Dos 134 pares elegíveis, todos atenderam aos critérios de estacionariedade; foram testadas 268 direções e 62 apresentaram significância após a correção de Benjamini–Hochberg. Esses resultados são preliminares e representam evidência de precedência temporal e capacidade preditiva no sentido de Granger, não uma demonstração isolada de causalidade econômica direta. Nas 62 relações significativas foram encontrados 6.149 choques na origem; 4.815 puderam ser classificados e 1.881 apresentaram resposta no destino dentro da janela de cinco datas de segunda a sexta. O modelo preditivo ainda não foi treinado, mas foram implementados a construção da base supervisionada, o protocolo de validação temporal, a comparação dos classificadores e a avaliação final isolada que orientarão essa próxima etapa.

Palavras-chave: CEASA; mineração de dados; séries temporais; pré-processamento; preços agrícolas; Efeito Dominó.

1 Introdução

1.1 Contextualização

As CEASAs concentram a comercialização atacadista de produtos agrícolas e produzem cotações que refletem condições de oferta, demanda, sazonalidade, logística e características regionais. Quando observados ao longo do tempo, esses registros permitem investigar se movimentos de preço permanecem locais ou se aparecem posteriormente em outros mercados.

O projeto considera três frentes de investigação: propagação de preços entre mercados, assimetria entre aumentos e reduções e períodos de elevada volatilidade. A etapa atual concentra-se na propagação de preços, denominada Efeito Dominó. As perguntas que orientam essas frentes são apresentadas na Seção de Objetivos.

Uma análise desse tipo exige séries comparáveis. Entretanto, a base contém diferenças de escrita nos produtos, múltiplas formas de apresentação, quantidades expressas em massa ou contagem, intervalos de peso, versões da mesma cotação e valores potencialmente suspeitos. Comparar diretamente os preços originais poderia confundir uma mudança de embalagem com uma variação econômica real.

Diante disso, foi construído um fluxo rastreável que parte do banco produzido pelo *crawler*, gera uma base pré-processada, organiza séries temporais, aplica o teste de Granger e caracteriza ocorrências

de Efeito Dominó. O banco bruto não é modificado e cada etapa gera uma saída derivada auditável. Até o momento, não foi realizado o treinamento de um modelo preditivo. Os programas que selecionam a configuração nas validações temporais e executam a avaliação final isolada já foram implementados, mas dependem da materialização da base de modelagem antes de serem executados.

O uso do termo Efeito Dominó neste projeto é uma analogia à propagação sequencial descrita em outras áreas. Na segurança de processos, por exemplo, um evento inicial pode produzir consequências sucessivas em outras unidades [1]. Neste trabalho, a propagação investigada não envolve acidentes: corresponde à possível transmissão temporal de informação entre os preços observados em mercados distintos.

1.2 Objetivos

1.2.1 Perguntas de pesquisa

O projeto foi organizado a partir das seguintes perguntas:

1. **Efeito Dominó:** usar os preços de outras CEASAs ajuda a prever aumentos de preços em um mercado específico?
2. **Efeito Foguete e Pena:** é possível identificar e prever situações em que os preços sobem mais rápido do que caem entre diferentes CEASAs?
3. **Agrupamento de Volatilidade:** é possível prever períodos de grandes oscilações nos preços de produtos agrícolas comercializados nas CEASAs?

A etapa atual do trabalho concentra-se na primeira pergunta. As demais serão desenvolvidas posteriormente.

1.2.2 Objetivo geral

Preparar e analisar as cotações históricas das CEASAs para investigar a existência de influência temporal entre entrepostos no sentido de Granger, preservando a rastreabilidade das transformações e evitando conversões sem evidência suficiente.

1.2.3 Objetivos específicos

- consolidar versões associadas à mesma cotação lógica;
- normalizar diferenças textuais sem misturar automaticamente produtos ou variedades distintas;
- interpretar unidades, embalagens, contagens e intervalos;
- calcular preços por quilograma, unidade-base ou item quando possível;
- identificar registros inadequados para a camada analítica;

- sinalizar e preservar possíveis *outliers*, mantendo-os fora da camada analítica principal sem apagar os valores originais;
- gerar um banco derivado reproduzível e validado;
- construir séries diárias comparáveis por produto e entreposto;
- verificar a estacionariedade das séries de retornos;
- testar a precedência temporal entre pares de entrepostos por meio da causalidade de Granger;
- caracterizar ocorrências de Efeito Dominó nas relações significativas;
- construir uma base supervisionada sem atributos posteriores ao choque;
- comparar classificadores por validação temporal com janelas crescentes e reservar o período final para uma única avaliação de teste.

1.3 Trabalhos relacionados

Swuste et al. [1] apresentam uma revisão histórica do conceito de efeito dominó em fábricas e agrupamentos da indústria química. Nesse contexto, o fenômeno é caracterizado por uma sequência na qual um evento inicial produz efeitos capazes de atingir outras unidades. Embora o domínio seja diferente, a noção de propagação espacial e sequencial contribui para delimitar a analogia empregada neste projeto. Aqui, os eventos analisados são movimentos de preço, e não acidentes industriais.

O teste proposto por Granger [2] verifica se valores passados de uma série acrescentam informação à previsão de outra série, além da informação já contida no próprio histórico da variável prevista. Portanto, a expressão causalidade de Granger indica precedência temporal com ganho preditivo e não, isoladamente, um mecanismo econômico causal.

No domínio de preços agrícolas, Oliveira et al. [3] analisaram séries mensais dos tomates Longa Vida e Cajá comercializados em Fortaleza e Ibiapaba, no Ceará, entre janeiro de 2011 e dezembro de 2022. Utilizando causalidade de Granger, o estudo identificou relação bilateral para o tomate Longa Vida e relação unidirecional de Fortaleza para Ibiapaba no caso do tomate Cajá. Esse resultado demonstra a aplicação do teste à transmissão regional de preços de um produto agrícola e fornece uma referência metodológica direta para a primeira pergunta desta pesquisa.

2 Métodos

2.1 Caracterização da base de dados

A base de origem é o arquivo `data/cotacoes.sqlite`, produzido pelo processo de coleta das cotações. O banco relaciona cotações, produtos, apresentações, entrepostos, CEASAs, coletas e proveniências. A origem das observações também permite distinguir os registros coletados diretamente daqueles provenientes do complemento PROHORT.

A execução encadeada documentada partiu de um retrato com 2.388.316 cotações. Após a seleção das coletas mais recentes e a consolidação de versões, foram obtidas 2.380.499 identidades. A exclusão de mapeamentos insuficientes resultou em 2.295.374 cotações gravadas no banco derivado. A Tabela 1 resume os principais indicadores observados nessa execução.

Tabela 1: Indicadores da execução encadeada documentada do pré-processamento.

Indicador	**Quantidade**
Cotações no retrato do banco bruto	2.388.316
Linhas associadas às últimas coletas	2.387.646
Identidades consolidadas	2.380.499
Cotações excluídas por mapeamento insuficiente	85.125
Cotações gravadas no banco derivado	2.295.374
Identidades com múltiplas versões	6.041
Apresentações catalogadas	1.941
Cotações com preço comum válido	2.091.322
Cotações com preço comum por kg	1.833.870
Cotações na camada analítica principal	2.090.611
Outliers desconsiderados da camada principal	711
Regras de conversão inferida aplicadas	13
Cotações com conversão inferida	3.250

Fonte: resumo do banco pré-processado ligado aos resultados documentados.

Essas quantidades descrevem o retrato ligado aos bancos de Granger e Efeito Dominó consultados. Como o crawler pode continuar acrescentando cotações, uma nova execução pode produzir números diferentes mesmo sem alteração dos critérios.

2.2 Visão geral do fluxo

A Figura 1 apresenta as etapas concluídas e as duas etapas seguintes já definidas. Cada banco derivado preserva a origem e os parâmetros de sua execução, permitindo reproduzir o caminho entre a coleta e os resultados estatísticos.

2.3 Ambiente e reprodutibilidade

O pré-processamento foi implementado em Python e executado em contêiner Docker. As dependências são gerenciadas pelo `uv`, enquanto o Docker Compose fornece um comando único para construção da imagem e execução do processo. O banco bruto é aberto somente para leitura, e o resultado é gravado em um novo arquivo, `resultados/preprocessamento/cotacoes_preprocessadas.sqlite`.

A substituição da saída é atômica: o novo banco é construído em um arquivo temporário e somente substitui a versão anterior após a conclusão das validações. Assim, uma falha durante o processamento não sobrescreve uma saída válida nem altera a fonte original.

Essa garantia é aplicada separadamente a cada etapa. O pipeline executa pré-processamento, Granger e Efeito Dominó em sequência, mas não confirma os três bancos em uma transação única. Se uma etapa posterior falhar, uma saída anterior já concluída pode ter sido atualizada, enquanto

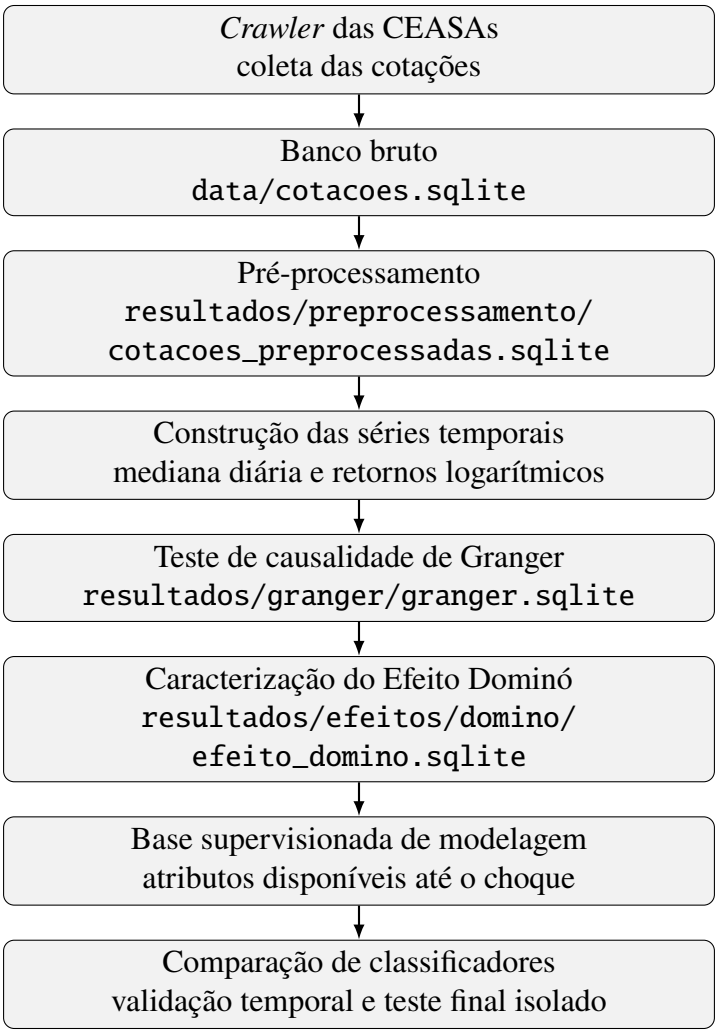


Figura 1: Fluxo metodológico executado e etapas seguintes definidas.

os bancos antigos das etapas seguintes permanecem preservados. A compatibilidade da cadeia é verificada pelos hashes, identificadores de execução e parâmetros registrados em cada artefato.

2.4 Política de retenção dos dados do crawler

O banco derivado não é uma cópia integral do banco do crawler. A seleção dos campos separa atributos da observação, informações necessárias para auditoria e estado operacional do coletor. As tabelas `backfill_states` e `schema_migrations` e campos como cursor, erro, caminho e hash do arquivo bruto e chaves internas de ocorrência permanecem somente no banco de origem. Eles descrevem o funcionamento da coleta, e não o preço, o produto, o mercado, a data ou a apresentação observada. Repeti-los na tabela analítica aumentaria a redundância e poderia confundi-los com variáveis econômicas.

Por outro lado, são preservados o identificador e as datas da coleta, os identificadores e nomes das dimensões, os textos originais do produto e da apresentação e os campos do complemento PROHORT. Esses dados permitem localizar a proveniência, interpretar a unidade original e distinguir informações diretas daquelas incorporadas pelo complemento. Portanto, os metadados operacionais não foram apagados: apenas permanecem na fonte, que continua sendo a camada de auditoria integral.

A tabela `cotacao_proveniencias` também não é copiada linha a linha. Como uma cotação pode estar ligada a mais de uma coleta, uma junção direta multiplicaria observações. Ela é usada para selecionar a coleta mais recente e para confirmar a proveniência, sem transformar registros de rastreamento em novas cotações.

2.5 Tipos de decisão sobre um registro

Neste trabalho, exclusão e filtro não são sinônimos. Foram adotadas quatro formas de tratamento:

- **preservação**: o valor original ou sua proveniência permanece disponível;
- **consolidação**: várias versões da mesma identidade passam a representar uma única observação;
- **exclusão da tabela final**: a linha não entra em `cotacoes_preprocessadas`, mas permanece no banco bruto e em `cotacoes_excluidas_mapeamento`;
- **desconsideração analítica**: a linha continua no banco derivado, porém não participa de uma visão ou teste cujos requisitos não atende.

Essa taxonomia evita interpretar “não usado em Granger” como “apagado do banco”.

2.6 Seleção e consolidação das cotações

A identidade lógica é representada por `chave_identidade`, fornecida pelo banco do crawler. O projeto de mineração trata essa chave como contrato de entrada e não a recalcula. Uma mesma identidade pode aparecer em diferentes coletas ou possuir versões simultâneas com preços distintos.

Para cada identidade, o processo seleciona a coleta mais recente registrada na tabela de proveniências. A ordenação usa a data de download, a data de processamento e, como desempate, o maior identificador da coleta. Quando a linha não está associada à coleta escolhida para sua identidade, ela permanece somente no histórico do banco bruto e não segue para a consolidação. Quando a coleta escolhida contém mais de uma versão, os preços mínimo, comum e máximo são consolidados separadamente pela mediana. A situação de mercado somente é mantida quando as versões concordam; em caso de conflito, fica nula. Essa regra evita escolher arbitrariamente uma versão e reduz a influência de um valor isolado. O banco derivado mantém uma linha por identidade e registra a quantidade de versões e a existência de conflito.

2.7 Normalização dos produtos

Os nomes dos produtos recebem uma chave textual sem diferenças de caixa, acentuação, espaços ou pontuação. A descrição original e o identificador do produto continuam preservados. A normalização permite reconhecer grafias equivalentes, mas não junta automaticamente variedades ou classificações que possam apresentar comportamentos de preço diferentes.

A regra remove espaços nas extremidades, ignora caixa, decompõe caracteres Unicode, retira acentos, substitui sequências não alfanuméricas por espaços e reduz espaços repetidos. O nome normalizado do banco tem prioridade; o alias original é usado apenas quando a primeira opção está vazia. Termos de variedade não são removidos, de forma que, por exemplo, pimentão e pimentão verde permanecem chaves distintas.

Descrições sem conteúdo utilizável, como `*`, recebem o marcador `produto_invalido`. Esses registros permanecem identificáveis no banco, mas não entram na visão analítica principal.

2.8 Tratamento das apresentações e unidades

As apresentações são classificadas segundo sua dimensão: massa, volume, contagem, unidade nativa ou combinação dessas formas. A apresentação original é preservada juntamente com a regra, a fórmula, a evidência e o nível de confiança utilizados na transformação.

Quando o peso total está explícito, a conversão é classificada como `exata`. Quando existem quantidade de itens e peso individual, o peso total é calculado pela multiplicação desses valores e a conversão é `calculada`. Unidades como dúzia e cento são convertidas para 12 e 100 itens, respectivamente, mas não recebem peso em quilogramas sem evidência do peso individual.

Volumes são preservados em litros, mas não convertidos para quilogramas porque a fonte não informa a densidade. Unidades nativas também são mantidas em sua própria base. O critério geral é somente criar R$/kg quando o denominador pode ser obtido de forma determinística ou por uma regra inferida que atenda a todos os controles descritos a seguir.

Intervalos como `CX 25-28 KG` preservam os limites mínimo e máximo. Um valor central não é criado, pois isso introduziria uma precisão inexistente na fonte. O mesmo princípio é aplicado às apresentações ambíguas: quando não é possível determinar o denominador do preço, a conversão para R$/kg não é realizada.

Também foi tratada uma inconsistência textual específica na qual o sufixo de origem PE aparece concatenado à unidade de massa. Dessa forma, Cx.20 KgPE é interpretado como 20 kg com o sufixo PE, enquanto Cx.23 a27KgPE permanece como intervalo de 23 a 27 kg.

O parser também reconhece intervalos com hífen antes da unidade, como Cx.17a18-Kg, preserva pesos totais explícitos quando o texto contém um intervalo independente de itens e identifica contagens explícitas de unidades ou vasos mesmo quando não existe unidade estruturada na fonte.

2.9 Conversões inferidas

Apresentações sem peso explícito podem ser comparadas com apresentações que possuem peso declarado para a mesma chave textual de produto, assinatura da apresentação e origem dos dados. A assinatura normaliza o texto e remove apenas termos de massa. Uma regra somente atende aos critérios estruturais quando candidato e âncora possuem ao menos cinco identidades e três datas, quando todos os pesos explícitos observados concordam e quando a data limite do treino foi informada.

Os preços não são utilizados para escolher o peso inferido. Essa decisão evita aproximar artificialmente os preços entre CEASAs e produzir o padrão de propagação que a pesquisa pretende investigar. Para impedir que informações futuras participem da criação das regras, a data limite de inferência foi fixada em 31 de outubro de 2025, a mesma data de corte do conjunto de treino. Somente registros com entreposto definido e preço comum positivo contam como suporte, mas o valor desse preço não participa da escolha do peso. Na execução documentada, 13 regras foram aplicadas a 3.250 cotações; outras 11 regras permaneceram apenas como candidatas por não atenderem a todos os critérios definidos.

2.10 Exclusões e indicadores de qualidade

Na versão atual do código, cotações que permanecem com os status sem_unidade, sem_quantidade_exata ou ambigua não são gravadas na tabela final. As quantidades excluídas por cada motivo são registradas em resumo_preprocessamento. As próprias linhas ficam disponíveis em cotacoes_excluidas_mapeamento, além de continuarem preservadas no banco bruto.

Na execução documentada, as 85.125 exclusões foram compostas por 85.108 registros sem unidade, 16 sem quantidade exata e um ambíguo. Essa distribuição é registrada para permitir que uma futura ampliação do parser seja avaliada pelo tipo de informação que ainda falta.

Apresentações ausentes, intervalos, volumes e unidades nativas não são automaticamente excluídos. Elas permanecem na tabela final com marcadores e somente ficam fora de análises que exigem uma massa total exata. Essa decisão preserva dados que ainda podem ser úteis em comparações na unidade original e evita tratar toda indisponibilidade de R$/kg como erro de coleta.

Preços comuns nulos, iguais a zero ou negativos são marcados como inválidos e ficam fora de cotacoes_analiticas. Quando a relação mínimo $\leq$ comum $\leq$ máximo não é respeitada, o preço comum tratado é mantido, mas os limites mínimo e máximo tratados ficam nulos. Essa decisão evita trocar ou ordenar automaticamente valores cuja coluna incorreta não pode ser determinada.

Os possíveis *outliers* são identificados dentro de grupos com o mesmo produto, entreposto e

apresentação. Com pelo menos cinco observações, preços por kg inferiores a 0,1 vez ou superiores a 10 vezes a mediana do grupo são sinalizados. Preço comum igual a R$ 0,01 ou razão inferior a 0,01 ou superior a 20 recebe a classificação `erro_provavel`. Entre os demais casos, grupos com pelo menos cinco ocorrências suspeitas recebem `inconsistencia_recorrente`; os restantes são classificados como `extremo_isolado`.

Entre os 711 casos sinalizados na execução documentada, 175 foram classificados como erro provável, 441 como inconsistência recorrente e 95 como extremo isolado.

Os valores sinalizados não são apagados nem corrigidos. Eles permanecem na tabela principal e nas visões de auditoria, mas ficam fora de `cotacoes_analiticas_principais`. Assim, não existe uma etapa de revisão manual obrigatória para que a base seja utilizada.

A etapa de Granger desconsidera todas as três classes de suspeita, e não apenas `erro_provavel`. O motivo é que não houve revisão externa capaz de separar um extremo econômico real de uma falha de denominador. A cotação continua disponível para que essa decisão possa ser revista futuramente.

A Tabela 2 resume a diferença entre exclusão e desconsideração analítica.

Tabela 2: Destino dos registros conforme a regra de qualidade.

Condição	**Destino**	**Critério e motivo**
Sem unidade, sem quantidade exata ou ambígua	Banco bruto e tabela de exclusões	Não existe denominador identificável com segurança; a linha não entra na tabela final, mas permanece auditável.
Sem apresentação, intervalo, volume ou unidade nativa	Tabela final com marcador	O dado pode ser útil em sua unidade original; somente fica fora de análises que exigem massa total exata.
Produto, preço comum ou dimensão inválida	Tabela final, fora da visão analítica	Falta uma dimensão essencial para interpretar a observação.
Outlier suspeito	Tabela final e visão de auditoria	O valor não é corrigido, mas não participa de Granger sem revisão externa.
Conversão incerta	Tabela final, fora de Granger	A comparação entre mercados exige preço em uma unidade comum.

2.11 Estrutura e validação da saída

O banco derivado contém a tabela principal `cotacoes_preprocessadas`, as visões `cotacoes_analiticas` e `cotacoes_analiticas_principais`, a tabela auditável de exclusões, o catálogo de apresentações, as regras de conversão, as classificações de *outliers*, o resumo e os parâmetros da execução.

Ao final, são verificadas a integridade interna do SQLite, a unicidade das identidades, a consistência dos marcadores, a cobertura do catálogo e a igualdade entre as quantidades consolidadas, gravadas e excluídas. A validação também confere a cobertura auditável das exclusões e garante que nenhum *outlier* permaneça na camada analítica principal. Essas verificações foram concluídas para o artefato de pré-processamento ligado aos resultados apresentados.

2.12 Construção das séries temporais

2.12.1 Recorte e critérios de entrada

O recorte atual considera 12 produtos e sete entrepostos: Recife, Grande Vitória, Curitiba, Maringá, Cascavel, Foz do Iguaçu e Londrina. Foram utilizadas cotações entre 4 de janeiro de 2022 e 31 de outubro de 2026, desde que possuam preço comum válido em R$/kg, não estejam sinalizadas como *outlier* e tenham conversão exata, calculada, padronizada ou inferida com alta confiança. O período até 31 de outubro de 2025 foi destinado à construção e ao diagnóstico das séries; o intervalo posterior foi preservado para avaliações futuras.

Antes dessa seleção, o programa exige que o banco pré-processado tenha uma execução concluída e que o limite temporal usado para inferir pesos seja igual ao fim do treino. Quando a origem bruta ainda está disponível, ela também não pode ser mais recente que o banco derivado. A etapa é interrompida se um dos sete mercados estiver ausente ou associado a mais de uma CEASA ou UF. Essas regras impedem a combinação de dados novos com conversões antigas, o uso de informação futura e a junção de mercados ambíguos.

Os sete entrepostos foram definidos na exploração anterior aos testes porque apresentavam mais de mil datas, cobertura multi-anual atual e sobreposição a partir de janeiro de 2022. Os outros 15 entrepostos do banco não foram removidos da base derivada: ficaram fora deste recorte por terem menos de mil datas, série encerrada antes do período ou coleta recente e curta.

Os 12 produtos formam uma cesta de interesse fixada na exploração inicial: batata, tomate, cebola, cenoura, morango, beterraba, melão, pimentão verde, pimentão, batata-doce, banana-prata e quiabo. A lista não foi determinada pelos p-valores e não corresponde a um ranking automático. A cobertura efetiva de cada combinação produto–mercados é verificada posteriormente, o que evita que a seleção substantiva substitua o critério amostral.

2.12.2 Agregação, preenchimento e retornos

Quando existe mais de uma cotação para o mesmo produto, entreposto e data, utiliza-se a mediana diária do preço comum em R$/kg. Sábados e domingos são desconsiderados nesta construção analítica, mas continuam preservados no banco pré-processado. Essa separação ocorre porque uma cotação de fim de semana não é necessariamente inválida: a exclusão atende à necessidade específica de formar séries regulares e defasagens comparáveis para Granger e Efeito Dominó, não a uma regra de qualidade aplicável a todas as análises. Falhas curtas podem ser preenchidas pelo último valor observado por, no máximo, três datas consecutivas de segunda a sexta. Lacunas maiores permanecem abertas para não criar continuidade artificial. Em seguida, os preços são transformados em retornos logarítmicos diários:

$$r_t = \ln(P_t) - \ln(P_{t-1}), \tag{1}$$

em que P_t representa a mediana diária do preço. Essa transformação direciona a análise às variações relativas, reduzindo o efeito dos diferentes níveis de preço entre mercados.

São materializadas as 84 combinações entre 12 produtos e sete mercados, inclusive as combinações sem dados. Cada ponto recebe um marcador que distingue cotação realmente observada de valor preenchido. Depois da terceira data consecutiva de segunda a sexta sem observação, inicia-se uma lacuna e a sequência seguinte recebe outro segmento. O retorno somente é calculado entre preços disponíveis no mesmo segmento; portanto, uma lacuna não pode produzir um retorno ou uma defasagem artificial. O calendário empregado representa todas as datas de segunda a sexta e não aplica uma lista de feriados nacionais, estaduais ou municipais. Assim, uma data de feriado sem cotação pode ser tratada como ausência e preenchida dentro do limite de três datas, enquanto uma cotação efetivamente registrada nessa data é mantida. Os valores preenchidos auxiliam o alinhamento dos calendários, mas não contam para admitir um par nem podem iniciar ou confirmar um evento de Efeito Dominó.

Na execução documentada, o recorte carregou 175.160 cotações, desconsiderou 320 registros de fim de semana e produziu 63.163 pontos diários observados e 8.545 pontos preenchidos. Nenhuma cotação inferida entrou nesse recorte específico.

2.13 Teste de causalidade de Granger

2.13.1 Formação e qualificação dos pares

Para cada produto, foram formados todos os pares possíveis entre os sete entrepostos, totalizando 252 pares candidatos. Um par somente é elegível quando as duas séries possuem ao menos 400 datas observadas de segunda a sexta em comum no período de treino. Pontos preenchidos não contam para esse limite. Pares sem observação recebem `serie_ausente`; os demais pares abaixo do limite recebem `dias_observados_insuficientes`. Todos permanecem registrados com o motivo. O limite corresponde a aproximadamente um ano e meio de observações em datas de segunda a sexta e evita estimar regressões com uma sobreposição curta. Além dos dias observados, registra-se a sobreposição disponível com preenchimento, mas ela não decide a elegibilidade. Nos pares aprovados, os retornos são recalculados em segmentos comuns, que são interrompidos por uma lacuna em qualquer uma das séries. Os retornos são então avaliados pelos testes ADF e KPSS; o par segue para Granger apenas quando as duas séries atendem simultaneamente aos critérios de estacionariedade.

2.13.2 Diagnóstico de estacionariedade

Os diagnósticos usam o maior segmento contínuo do par. Cada série deve conter ao menos 30 retornos, não ser constante, apresentar ADF com $p < 0{,}05$ e KPSS com $p > 0{,}05$. Exigir concordância dos dois testes reduz a dependência de uma única hipótese nula. O ADF usa constante e escolhe internamente suas defasagens pelo BIC; o KPSS usa constante e seleção automática de defasagens. Amostra insuficiente, série constante ou erro numérico reprova o par e mantém o motivo no banco. As duas direções recebem `nao_estacionario` e não participam da correção de múltiplos testes.

2.13.3 Especificação, seleção de lags e significância

As duas direções de cada par são testadas separadamente. São avaliadas de uma a dez defasagens em uma amostra fixa, e a quantidade de defasagens é escolhida pelo Critério de Informação Bayesiano

(BIC). O teste F verifica se os valores passados da série de origem acrescentam informação à previsão da série de destino. Como várias hipóteses são avaliadas, os valores p recebem correção global de Benjamini–Hochberg, com taxa de falsas descobertas de 5% [4].

Para uma direção $A \rightarrow B$ e um lag p, o modelo restrito contém apenas o passado do destino:

$$r_t^B = c + \sum_{i=1}^{p} \phi_i r_{t-i}^B + \varepsilon_t, \tag{2}$$

enquanto o modelo irrestrito acrescenta o passado da origem:

$$r_t^B = c + \sum_{i=1}^{p} \phi_i r_{t-i}^B + \sum_{i=1}^{p} \beta_i r_{t-i}^A + \varepsilon_t. \tag{3}$$

O teste F compara esses modelos. Matriz sem posto completo, amostra insuficiente ou resíduo nulo produz `erro_modelo`, e não um valor p artificial.

A amostra de todos os lags começa depois da décima defasagem, mesmo quando o modelo avaliado usa menos lags. Isso impede que o BIC favoreça um modelo apenas por ter recebido mais observações. Segmentos separados por lacunas não são concatenados e, em caso de empate no BIC, escolhe-se o menor lag. Todos os dez resultados são preservados, mas somente o valor p do lag escolhido em cada direção com status `testado` participa da correção global. A aprovação principal exige $q < 0{,}05$; significância apenas no valor p bruto não envia a relação para o Efeito Dominó.

Um resultado significativo é interpretado como evidência de influência temporal preditiva no sentido de Granger. Ele não prova, sozinho, que um entreposto provoque diretamente a alteração de preço no outro, pois fatores externos ou variáveis não observadas também podem explicar a relação.

2.13.4 Validação e rastreabilidade

O banco de Granger registra o caminho, o tamanho e o hash SHA-256 do banco pré-processado, o identificador da execução de origem e todos os parâmetros do recorte. Também preserva as séries, os pares rejeitados e seus motivos, os diagnósticos de estacionariedade, os resultados de todos os lags e os coeficientes do modelo escolhido.

Antes da substituição do arquivo anterior, são verificadas a integridade do SQLite e suas chaves estrangeiras, a aplicação do limite mínimo de cobertura, a presença das duas direções para cada par elegível, os dez resultados de lag para cada direção testada, a seleção de um lag entre 1 e 10 e a permanência dos valores q no intervalo de zero a um. Essas verificações confirmam a coerência interna do artefato, mas não transformam associação temporal em causalidade econômica.

2.14 Caracterização do Efeito Dominó

2.14.1 Relações analisadas e definição de choque

O resultado de Granger é utilizado como um mapa das relações que devem ser observadas, e não como um modelo de previsão. Para cada produto, somente as direções que permaneceram significativas após a correção FDR são examinadas. Em seguida, as séries são percorridas cronologicamente para

localizar uma alta no mercado de origem e verificar se ela foi seguida por uma alta no mercado de destino.

Uma alta é considerada forte quando supera simultaneamente 5% e o percentil 90 dos retornos daquele produto e entreposto. O percentil é calculado apenas com o período de treino, impedindo que dados do período de teste influenciem a regra. Tanto o movimento inicial quanto a resposta são determinados por cotações realmente observadas; valores preenchidos para cobrir falhas curtas não podem iniciar nem confirmar um evento.

Como os retornos são logarítmicos, o piso de 5% é representado por $\ln(1 + 0{,}05)$. Para cada produto e mercado, o limite usado é

$$L = \max\left\{\ln(1 + 0{,}05),\ Q_{0,90}(r_{\text{treino,obs}})\right\}. \tag{4}$$

O limite é próprio de cada produto e mercado, em vez de um valor único para toda a base, porque a distribuição das variações difere entre séries. O piso de 5% evita classificar como choque uma variação pequena em uma série estável; o percentil 90 adapta a exigência quando a volatilidade histórica é maior.

2.14.2 Classificação dos eventos

Para uma relação direcionada $A \rightarrow B$, a caracterização segue os passos abaixo:

1. localizar uma alta forte do produto no entreposto A;
2. confirmar que existe uma cotação observada em B na mesma data;
3. desconsiderar como propagação os casos em que A e B já apresentam uma alta forte simultaneamente;
4. observar as cotações de B nas cinco datas de segunda a sexta seguintes, sem atravessar a divisão entre treino e teste;
5. registrar Efeito Dominó quando a alta acumulada em B atingir o limite calculado para sua própria série, usando como base o preço observado em B na data inicial.

Quando existe ao menos uma cotação futura observada no destino, mas a resposta não ocorre dentro da janela, o caso é marcado como não propagado. Casos sem cotação inicial no destino, sem nenhuma observação posterior ou com movimento simultâneo são preservados para auditoria, mas não recebem rótulo positivo ou negativo. Essa distinção evita transformar ausência de dados em ausência de propagação. A resposta registrada é a primeira data observada em que a alta acumulada atinge o limite, e não necessariamente a data da maior alta na janela.

A Tabela 3 explicita a decisão atribuída a cada condição. A janela pode conter menos de cinco cotações: uma única observação futura já permite o rótulo negativo se o limite não for atingido; somente a ausência total de observações futuras representa falta de cobertura.

A unidade resultante representa um produto, uma origem, um destino e a data da alta inicial. Assim, a nova base indicará explicitamente os casos em que a propagação foi observada e aqueles em

Tabela 3: Regras de classificação dos candidatos ao Efeito Dominó.

Condição	Rótulo	Decisão
Cotação futura observada atinge o limite	1	`confirmado`; registra a primeira resposta.
Cotação futura existe, mas não atinge o limite	0	`nao_confirmado`; houve cobertura para testar a regra.
Destino também supera seu limite na data inicial	Nulo	`movimento_simultaneo`; não há propagação posterior.
Destino sem base observada ou com preço-base inválido	Nulo	Não existe referência comparável para calcular a alta acumulada.
Nenhuma cotação futura observada na janela	Nulo	`sem_cobertura_destino`; falta de dado não equivale a ausência de efeito.

que ela não ocorreu. Essa adaptação segue a ideia de um evento inicial que produz uma consequência posterior em outra unidade, presente na literatura de efeito dominó [1], aplicada aqui à transmissão temporal de preços.

2.14.3 Rastreabilidade e validação

A caracterização foi gravada em `resultados/efeitos/domino/efeito_domino.sqlite`, sem modificar os bancos anteriores. A execução pode ser feita isoladamente ou pelo pipeline completo, que executa pré-processamento, Granger, caracterização e construção da base de modelagem em sequência.

O banco registra o caminho e o hash SHA-256 do banco de Granger, o identificador da execução de origem, as relações recebidas e os parâmetros usados. Antes de substituir a saída anterior, o processo verifica a integridade do SQLite, a correspondência entre o resumo e as quantidades de choques, eventos classificáveis, confirmações e não confirmações, além de exigir que todo rótulo 1 tenha status `confirmado` e todo rótulo 0 tenha status `nao_confirmado`.

2.15 Construção da base de modelagem

A nova etapa foi implementada para produzir o quarto banco derivado, `resultados/modelagem/base_modelagem.sqlite`, destinado ao treinamento e à avaliação dos classificadores. O script recebe os bancos pré-processado, de Granger e do Efeito Dominó. Antes de construir qualquer linha, verifica se as três execuções estão concluídas, calcula seus hashes SHA-256 e confere a cadeia de procedência: o hash do pré-processamento deve ser o registrado pelo Granger, e o hash do Granger deve ser o registrado pelo Efeito Dominó. Os identificadores das execuções também devem coincidir.

O banco pré-processado participa como origem indireta e como elemento de rastreabilidade. Suas cotações individuais não são juntadas novamente aos eventos, pois várias apresentações podem existir para o mesmo produto, mercado e dia, o que duplicaria linhas e voltaria a misturar preços não comparáveis. Os atributos diários usam as séries já agregadas pelo Granger, cuja mediana, conversões e contagens foram produzidas a partir desse banco pré-processado.

2.15.1 Unidade de análise, alvo e elegibilidade

Cada linha representa um evento candidato identificado por produto, mercado de origem, mercado de destino e data do choque. A tabela do Efeito Dominó fornece as linhas e a variável-alvo:

- `efeito_domino`=1 quando existe resposta confirmada no destino dentro da janela de cinco datas de segunda a sexta;
- `efeito_domino`=0 quando existe base e cobertura posterior observadas, mas a resposta não alcança o limite;
- rótulo nulo quando o evento é simultâneo, não existe base comparável no destino ou não existe observação futura que permita classificá-lo.

Somente os rótulos 0 e 1 recebem `elegivel_modelagem`=1 e podem entrar nas partições. Os eventos nulos permanecem no banco para auditoria, sem serem convertidos artificialmente em exemplos negativos. O campo `grupo_choque`, formado por produto, origem e data do choque, identifica linhas que nasceram do mesmo movimento inicial, mas não as colapsa: cada destino continua representando uma pergunta preditiva distinta.

A regra atual para o rótulo 0 exige ao menos uma cotação futura observada, mas não exige que todas as cinco datas da janela possuam cotação. Portanto, um negativo com cobertura parcial significa que a resposta não foi observada nos dias disponíveis, e não que sua ausência foi comprovada em cinco observações. Essa diferença é mantida no banco e será reavaliada antes da interpretação definitiva do treinamento; a implementação não remove nem converte esses casos silenciosamente.

2.15.2 Construção dos atributos

Os atributos são calculados separadamente para origem e destino e usam somente informações disponíveis até a data do choque. O script produz 81 preditores, organizados na Tabela 4.

Valores ausentes nos primeiros dias de uma série ou depois de lacunas são preservados; não são preenchidos globalmente durante a criação do banco. Imputação, padronização e codificação categórica serão ajustadas novamente somente com o treino de cada divisão e então aplicadas à respectiva validação ou teste.

2.15.3 Separação entre preditores e auditoria

A tabela `eventos_modelagem` contém identificadores, preditores, alvo e o indicador de elegibilidade. Data de resposta, dias até a resposta, maior alta futura, quantidade de observações futuras, status do evento e demais campos calculados após o choque são gravados somente em `auditoria_eventos`. Essa separação física reduz o risco de inclusão acidental de informação futura na matriz de atributos.

O banco também contém `catalogo_atributos`, que registra para cada coluna seu papel, tipo, origem, regra de construção e se pode entrar no modelo; `fontes_dados`, com caminho, hash, execução e versão de cada entrada; `particoes_modelagem`, com o papel temporal de cada evento; e `resumo_modelagem`, com as contagens da execução. O arquivo é construído em um SQLite

Tabela 4: Grupos de atributos construídos para a base de modelagem.

Grupo	**Atributos**	**Regra e finalidade**
Identificação da relação	Produto, origem, destino, UFs e indicador de mesmo estado	Caracterizam a relação sem usar o resultado futuro; produto e mercados serão tratados como categorias pelo classificador.
Calendário	Ano, mês, trimestre e dia da semana	Derivados exclusivamente da data do choque para representar tendência temporal e sazonalidade.
Relação de Granger	Lag selecionado, estatística F, p-valor e q-valor FDR	Atributos fixos da relação significativa. Nas validações internas, permanecem condicionados à rede definida no desenvolvimento completo.
Choque e limites	Alta logarítmica e percentual, limites da origem e do destino, excesso logarítmico e razão entre alta e limite	Medem a intensidade do choque em relação ao critério histórico usado para defini-lo.
Preços na data	Preços em R$/kg, logaritmos e diferença entre os logaritmos	Usam somente os preços da origem e do destino observados na data do choque; nenhum preço posterior participa.
Qualidade da observação	Quantidades de cotações exatas, calculadas, padronizadas e inferidas	Registram quanto e que tipo de evidência compôs o preço diário em cada mercado.
Defasagens	Retornos anteriores de 1 a 10 datas de segunda a sexta, para origem e destino	Obtidos por deslocamento em ordem crescente dentro do mesmo segmento contínuo; o retorno do próprio dia é armazenado separadamente.
Janelas históricas	Média, desvio-padrão e soma dos retornos em 5, 10 e 20 datas de segunda a sexta	Janelas encerradas na data do choque e calculadas dentro do mesmo segmento contínuo, com no mínimo uma observação, para não atravessar lacunas longas da série.
Cobertura histórica	Proporção de dias realmente observados nas janelas de 5, 10 e 20 dias	Distingue histórico observado de valores preenchidos e informa a qualidade recente da série.

temporário, validado por integridade e coerência das contagens e somente então substitui a saída anterior.

2.15.4 Protocolo de validação temporal

Será adotada validação temporal com janelas crescentes, seguindo o mesmo desenho geral empregado no trabalho anterior de previsão do top 10 da Fórmula 1. A primeira divisão treinará com eventos de 2022 e 2023 e validará em 2024. A segunda treinará com eventos de 2022 a 2024 e validará de janeiro a outubro de 2025. Não haverá distribuição aleatória dos registros.

Como o rótulo do Efeito Dominó observa as cinco datas de segunda a sexta posteriores ao choque, cada evento recebe a data nominal em que seu rótulo estaria totalmente disponível. A regra de purga exclui de cada divisão todo evento cuja janela ultrapasse o fim do período ao qual foi atribuído. Assim:

- eventos de treino que alcançam a validação são excluídos daquele treino;
- eventos de validação cuja janela termina depois do fim da validação também são excluídos;
- no ajuste final, eventos anteriores a novembro de 2025 cuja janela atravessa o corte não entram no treino;
- eventos do teste cuja janela ultrapassa 31 de outubro de 2026 não entram na avaliação final.

Não há distribuição aleatória. Eventos com o mesmo `grupo_choque` compartilham produto, origem e data e, por consequência, permanecem no mesmo lado da fronteira temporal. O agrupamento é preservado como identificador para análises de dependência ou ponderação posteriores; a base atual não elimina destinos distintos associados ao mesmo choque.

São criadas seis views específicas:

- `treino_validacao_1` e `validacao_1`;
- `treino_validacao_2` e `validacao_2`;
- `treino_final` e `teste_final`.

Todas contêm apenas eventos classificáveis que passaram pela regra temporal correspondente.

Essas views constituem o contrato entre a construção da base e o treinamento. O programa de seleção recebe somente as quatro views de desenvolvimento. As duas views finais são consumidas por outro programa, executado por um comando separado, para reduzir o risco de consulta acidental ao teste oficial.

2.16 Treinamento, seleção e avaliação final

2.16.1 Escopo dos dados e separação das etapas

O treinamento consome exclusivamente `resultados/modelagem/base_modelagem.sqlite`. Nenhum banco de clima, câmbio, inflação, transporte ou outra fonte externa é integrado nesta versão.

Essa restrição mantém a pergunta experimental alinhada ao banco já construído: verificar quanto os atributos históricos, a relação entre mercados e o choque observado explicam a propagação registrada.

A implementação foi dividida em dois comandos:

1. `validacao-modelos`, responsável por ajustar e comparar as configurações somente nas duas divisões de desenvolvimento;
2. `avaliacao-final`, responsável por reajustar a configuração escolhida em todo o treino final e somente depois consultar o teste oficial.

Há também o orquestrador dedicado `pipeline-treinamento-avaliacao`, que chama esses dois comandos em ordem após uma invocação explícita. Ele não integra o `pipeline-completo`. Assim, recriar o pré-processamento, o Granger, os eventos ou a base de modelagem não abre automaticamente o período reservado. A separação é uma barreira operacional: o teste continua tecnicamente acessível ao comando final e ao orquestrador dedicado, mas deixa de fazer parte do ciclo repetido de desenvolvimento.

2.16.2 Validação da entrada

Antes de ajustar modelos, o programa exige uma execução de modelagem com status `concluida`, o catálogo de atributos e as quatro views de desenvolvimento. Cada view deve ser não vazia, possuir todas as colunas registradas, conter somente alvos 0 e 1, apresentar as duas classes e não ter identificadores de evento duplicados. Em cada divisão, a maior data do treino deve ser anterior à menor data da validação e nenhum identificador pode aparecer nos dois lados.

Essas verificações não substituem a regra de construção das partições, mas impedem que uma base incompleta ou uma alteração acidental das views seja aceita silenciosamente pelo treinamento. O hash SHA-256 da base e o identificador de sua execução são registrados junto dos resultados.

2.16.3 Preparação dos atributos dentro de cada treino

O catálogo da base determina quais colunas podem entrar nos classificadores. Dos 81 preditores, oito são tratados como categóricos: produto, origem, destino, UF da origem, UF do destino, mês, trimestre e dia da semana. Mês, trimestre e dia da semana são categorias porque seus códigos não representam uma distância linear: dezembro não deve ser interpretado como doze vezes janeiro, por exemplo. Os 73 restantes seguem o fluxo numérico; entre eles, o ano permanece numérico para representar a progressão temporal.

Para evitar vazamento, cada ajuste cria um novo pipeline e aprende as transformações somente com o treino daquela divisão. O procedimento é:

- valores numéricos não interpretáveis ou infinitos são tratados como ausentes;
- cada atributo numérico ausente recebe a mediana calculada no treino; quando a ausência aparece no treino, acrescenta-se um indicador binário para que o modelo possa distinguir valor observado de valor imputado;

- os atributos numéricos são padronizados pela média e pelo desvio-padrão do treino;
- categorias ausentes recebem uma categoria explícita de ausência;
- as categorias são convertidas por codificação one-hot; categorias inéditas na validação ou no teste são ignoradas, em vez de causar erro ou provocar novo ajuste.

A mediana reduz a influência de valores extremos e a padronização coloca atributos com escalas diferentes em condição comparável, especialmente para Regressão Logística e SVM. Árvores não dependem da escala, mas usam a mesma representação para manter um fluxo uniforme. A baseline por relação é a única exceção: ela usa diretamente produto, origem e destino, pois sua finalidade é medir quanto se obtém apenas com a frequência histórica daquela relação.

2.16.4 Baselines, classificadores e configurações

A busca é deliberadamente pequena e determinística. O volume disponível é adequado para uma comparação inicial de modelos tabulares, mas não justifica redes neurais nem uma exploração extensa de hiperparâmetros. Ao todo são 25 configurações, resumidas na Tabela 5.

Tabela 5: Configurações comparadas na seleção dos classificadores.

Família	**Configurações**	**Finalidade**
Prevalência	Uma configuração com a proporção positiva do treino	Referência mínima que não explora atributos.
Taxa histórica por relação	Suavização 5 e 20	Mede o poder preditivo da frequência histórica de produto–origem–destino.
Regressão Logística	$C \in \{0{,}1; 1; 10\}$, com e sem pesos de classe	Referência linear, probabilística e interpretável.
Árvore de Decisão	Profundidade 4 ou 8, mínimo de 10 amostras por folha, com e sem pesos de classe	Captura regras e interações não lineares com complexidade limitada.
Random Forest	300 árvores, mínimo de 2 ou 5 amostras por folha, $\sqrt{p}$ atributos por divisão de nó, com e sem pesos de classe	Reduz a instabilidade de uma árvore e representa interações.
Gradient Boosting	150 árvores, profundidade 2 e taxa 0,05 ou 0,10	Constrói correções sucessivas de baixa profundidade.
SVM com núcleo RBF	$C \in \{0{,}5; 1; 2\}$, com e sem pesos de classe	Compara uma fronteira não linear baseada em distância.

A baseline de prevalência devolve para todos os eventos a proporção positiva observada no treino. Na baseline histórica, para uma relação r, a probabilidade estimada é

$$\widehat{p}_r = \frac{s_r + \lambda \widehat{p}}{n_r + \lambda}, \tag{5}$$

em que s_r é o número de positivos da relação, n_r é sua quantidade de eventos, $\widehat{p}$ é a prevalência global do treino e $\lambda \in \{5, 20\}$ controla a suavização. Relações não observadas no treino recebem a prevalência global. A suavização evita probabilidades extremas em relações com poucas observações.

Nas configurações com pesos de classe, a classe menos frequente recebe peso inversamente proporcional à sua frequência. Não se aplica SMOTE nesta primeira comparação: a proporção positiva está próxima de 39%, e criar eventos sintéticos poderia misturar relações, grupos de choque e dependências temporais que não correspondem a observações reais. Pesos de classe e ajuste do limiar permitem investigar o desequilíbrio sem fabricar novas linhas.

Todos os modelos estocásticos usam a semente configurável `TREINAMENTO_SEMENTE`, cujo valor padrão é 42. A semente torna as comparações reproduzíveis; ela não elimina a necessidade de registrar versões, dados e parâmetros.

2.16.5 Ajuste nas validações e escolha do limiar

Cada configuração é ajustada duas vezes, sempre do zero:

1. treino em 2022–2023 e previsão probabilística em 2024;
2. treino em 2022–2024 e previsão probabilística entre janeiro e outubro de 2025.

Não há embaralhamento dos eventos nem validação aleatória. Para cada configuração, um único limiar é escolhido para as duas validações entre os valores 0,05 e 0,95, em passos de 0,05. Em cada limiar calcula-se o F1 separadamente nas duas divisões e usa-se a média. O maior F1 médio vence; em caso de igualdade, o desempate usa, nesta ordem, MCC médio, precisão média e proximidade de 0,50. Esse limiar é então usado para registrar todas as métricas da configuração.

Depois que cada configuração possui seu melhor limiar, a escolha do modelo usa o maior F1 médio. Empates são resolvidos pela maior PR-AUC média, pelo maior MCC médio e, por fim, pela ordem fixa do catálogo de configurações. O último critério não expressa superioridade metodológica; apenas garante que uma igualdade exata produza sempre o mesmo resultado.

O F1 da classe positiva é o critério principal porque combina precisão e revocação:

$$F1 = 2\frac{\text{precisao} \times \text{revocacao}}{\text{precisao} + \text{revocacao}}. \tag{6}$$

Assim, não basta prever muitos positivos nem obter acurácia elevada pela classe mais frequente. A PR-AUC complementa o F1 avaliando a ordenação probabilística ao longo de vários limiares, enquanto o MCC resume os quatro quadrantes da matriz de confusão e penaliza soluções degeneradas.

2.16.6 Métricas e dependência entre eventos

Para cada configuração e validação são armazenados F1, precisão, revocação, acurácia, acurácia balanceada, MCC, PR-AUC, ROC-AUC, erro de Brier e as quatro contagens da matriz de confusão. A acurácia balanceada dá o mesmo peso à taxa de acerto de cada classe; o Brier mede o erro quadrático das probabilidades e, portanto, ajuda a distinguir classificação correta de probabilidade bem calibrada.

Como vários destinos podem nascer do mesmo choque na origem, também é feita uma análise de sensibilidade por `grupo_choque`. Se um grupo g possui n_g linhas, cada uma recebe peso

$$w_i = \frac{1}{n_g}. \tag{7}$$

Desse modo, todo grupo soma peso 1, independentemente da quantidade de destinos associados. F1, precisão, revocação e acurácia são recalculados com esses pesos. Essas medidas são complementares: não alteram o ajuste, o limiar nem a escolha principal do modelo, mas mostram se grupos com muitos destinos estão dominando o resultado convencional por linha.

2.16.7 Saídas e rastreabilidade da seleção

A seleção grava `resultados/treinamento/validacao.sqlite`. O banco contém:

- identificação da execução, hash e caminho da base, semente, critério de seleção e a declaração de que o teste final não foi consultado;
- catálogo das 25 configurações e indicação da selecionada;
- limiar e resumo médio de cada configuração;
- métricas por configuração e divisão;
- probabilidade, previsão, alvo, data e grupo de cada evento validado.

Também é criado `resultados/treinamento/configuracao_selecionada.json`, que registra o hash e a execução da base, a lista e a assinatura dos atributos, a semente, as quatro views consultadas, o modelo, os hiperparâmetros, o limiar e o resumo das validações. O JSON é o contrato consumido pela avaliação final. As saídas da seleção são escritas primeiro em arquivos temporários e somente substituem os destinos depois da validação de integridade do SQLite. Como a seleção pertence ao desenvolvimento, o serviço permite sua reconstrução explícita.

2.16.8 Ajuste e avaliação final isolada

Antes da avaliação oficial, o segundo programa verifica se o JSON corresponde ao formato esperado, se declara não ter consultado o teste e se lista exatamente as quatro views de desenvolvimento. O código, a família e os hiperparâmetros devem coincidir com uma das configurações implementadas. Em seguida, são comparados com a base atual o hash SHA-256, o identificador da execução, a lista de atributos e sua assinatura.

Somente após essas verificações a configuração escolhida é ajustada em `treino_final`, que contém o desenvolvimento disponível até 31 de outubro de 2025. O programa conclui esse ajuste antes de ler `teste_final`. A ordem temporal e a ausência de identificadores compartilhados são verificadas novamente. O modelo, os hiperparâmetros, o pré-processamento e o limiar permanecem fixos durante a avaliação entre 1º de novembro de 2025 e 31 de outubro de 2026.

A avaliação produz `resultados/treinamento/avaliacao_final.sqlite`, com métricas, previsões e importâncias absolutas quando o estimador fornece coeficientes ou importância de atributos. Também serializa o pipeline ajustado em `resultados/treinamento/modelo_final.pkl`, acompanhado pelos hashes, pela configuração e pela versão do scikit-learn. O formato serializado deve ser reaberto no mesmo ambiente de dependências ou em ambiente compatível.

Por padrão, a avaliação final recusa sobrescrever tanto o banco quanto o modelo serializado. O serviço do Docker Compose não ativa a opção de sobrescrita. Essa proteção reduz repetições acidentais, embora uma repetição consciente continue possível por opção explícita ou por outro caminho de saída. O hash do JSON efetivamente usado é registrado para permitir auditoria posterior.

O pipeline dedicado antecipa essa verificação: antes de refazer a validação, ele recusa iniciar se o banco da avaliação final ou o modelo serializado já existir. Desse modo, não substitui os resultados

de desenvolvimento para somente depois descobrir que a etapa oficial está protegida. Quando não há artefatos finais, ele refaz a seleção e só abre o teste se essa primeira etapa terminar com sucesso. Por prosseguir diretamente até o teste oficial, esse orquestrador deve ser invocado apenas quando a metodologia e a seleção estiverem encerradas.

3 Resultados

3.1 Resultados do teste de Granger

A Tabela 6 resume a execução documentada. Dos 252 pares candidatos, 134 atenderam ao mínimo de sobreposição e todos passaram pelos diagnósticos de estacionariedade. Isso produziu 268 direções testadas, das quais 80 seriam significativas sem ajuste e 62 permaneceram significativas após a correção global.

Tabela 6: Resumo dos resultados atuais do teste de Granger.

Indicador	**Quantidade**
Cotações carregadas no recorte	175.160
Pares candidatos	252
Pares com série ausente	53
Pares com cobertura observada insuficiente	65
Pares elegíveis e estacionários	134
Direções testadas	268
Direções significativas sem correção	80
Direções significativas após correção FDR	62
Pares com ao menos uma direção significativa	50
Relações unidirecionais	38
Relações bidirecionais	12

Fonte: banco `resultados/granger/granger.sqlite` da execução documentada.

3.2 Resultados da caracterização do Efeito Dominó

A Tabela 7 resume a execução documentada. Entre os 4.815 eventos classificáveis, 1.881 foram confirmados, correspondendo a 39,1%. A proporção foi semelhante no treino e no teste, com 39,0% e 39,2%, respectivamente.

Todas as 62 relações apresentaram ao menos um evento classificável e uma confirmação. Entre as confirmações, 610 ocorreram na primeira data de segunda a sexta posterior ao choque e 449 na segunda.

Entre os 2.934 rótulos negativos, 908 possuem menos de cinco cotações futuras observadas no destino. Esses registros não estão comprovadamente errados: eles seguem a regra atual, segundo a qual ao menos uma observação futura sem resposta já permite o rótulo 0. Entretanto, representam negativos com evidência mais fraca do que uma janela completamente observada. A base de treinamento os preserva, e a exigência de cobertura completa será decidida antes da execução definitiva ou tratada em análise de sensibilidade específica.

Tabela 7: Resumo da caracterização atual do Efeito Dominó.

Indicador	Quantidade
Relações de Granger analisadas	62
Choques encontrados na origem	6.149
Eventos classificáveis	4.815
Efeitos confirmados	1.881
Efeitos não confirmados	2.934
Movimentos simultâneos	841
Eventos sem base observada no destino	470
Eventos sem cobertura posterior	23

Fonte: banco `resultados/efeitos/domino/efeito_domino.sqlite` da execução documentada.

3.3 Distribuição temporal para a modelagem

A Tabela 8 apresenta a quantidade de eventos classificáveis em cada recorte antes da purga das fronteiras. Essas quantidades descrevem a disponibilidade bruta no banco do Efeito Dominó, não o número final de linhas que será entregue pelas views de modelagem. A taxa positiva permaneceu entre 37,4% e 40,8%, sem desbalanceamento extremo entre os períodos.

Tabela 8: Distribuição bruta dos eventos antes da purga temporal.

Divisão	Total	Positivos	Negativos	Positivos (%)
Treino da divisão 1: 2022–2023	1.651	673	978	40,8
Validação da divisão 1: 2024	1.212	461	751	38,0
Treino da divisão 2: 2022–2024	2.863	1.134	1.729	39,6
Validação da divisão 2: jan.–out. de 2025	1.018	381	637	37,4
Treino final: até out. de 2025	3.881	1.515	2.366	39,0
Teste final: nov. de 2025–out. de 2026	934	366	568	39,2

Fonte: banco `resultados/efeitos/domino/efeito_domino.sqlite`. As contagens definitivas deverão ser obtidas de `resultados/modelagem/base_modelagem.sqlite` após sua execução.

Antes da purga, as duas validações contêm eventos dos dez produtos e das 62 relações. Na primeira, 61 relações apresentam as duas classes; na segunda, todas apresentam ao menos um evento positivo e um negativo. Entretanto, a quantidade por relação é pequena em alguns casos: os mínimos são três eventos em 2024 e cinco entre janeiro e outubro de 2025. O recorte bruto do teste final contém 58 das 62 relações, portanto os resultados agregados desse período não representarão quatro relações sem evento classificável. Essas coberturas deverão ser recalculadas após a materialização das views.

4 Discussão

4.1 Interpretação das relações temporais

Os resultados mostram, no recorte analisado, evidências de influência temporal entre determinados entrepostos. Tomate, batata e morango concentraram, respectivamente, 14, 13 e 11 direções significativas. Curitiba e Maringá foram as origens mais frequentes entre as relações significativas, com 18 e 15 direções. A interpretação permanece restrita à precedência temporal preditiva no sentido de Granger; fatores externos ou variáveis não observadas podem explicar parte das relações.

4.2 Suficiência e dependência das observações

O recorte bruto reúne 3.881 eventos no treino final, quantidade próxima da que restará após a purga e suficiente para planejar uma comparação inicial de classificadores tabulares sob um modelo global. Essa suficiência deverá ser confirmada com a contagem materializada. A estabilidade da proporção positiva e a presença das duas classes nas validações favorecem esse desenho. O volume, porém, não sustenta modelos independentes para cada relação, produto ou par de mercados, nem justifica inicialmente redes neurais ou buscas muito amplas de hiperparâmetros.

As linhas não são completamente independentes. Antes da purga, o treino reúne 2.211 choques de origem distintos distribuídos em 798 datas. Além disso, foram identificados 433 grupos nos quais mais de um choque foi associado ao mesmo produto, destino e data de resposta, totalizando 647 registros adicionais. A base preserva cada destino como uma observação distinta e registra o `grupo_choque` para identificar eventos que compartilham produto, origem e data. A separação temporal impede que o mesmo grupo atravesse treino e avaliação. A implementação do treinamento já calcula métricas complementares nas quais cada grupo possui o mesmo peso total; o efeito dessa ponderação sobre as conclusões somente poderá ser examinado depois da execução.

4.3 Limitações e próxima etapa

A decisão de preservar cotações de fim de semana no pré-processamento e desconsiderá-las somente nas séries temporais é provisória. Depois da análise dos demais efeitos, essa regra será reavaliada considerando as necessidades de todas as etapas. Até essa revisão, os registros não serão excluídos da base pré-processada, pois podem ser válidos para outras análises. Também permanece como trabalho futuro avaliar calendários específicos por entreposto para tratar feriados nacionais, estaduais e municipais sem remover datas em que um mercado tenha operado normalmente.

A futura avaliação medirá a capacidade de prever a propagação entre relações previamente selecionadas por Granger. Ela não demonstrará, por si só, que o mesmo desempenho se estende a pares sem relação significativa. Será necessário comparar posteriormente os resultados com um controle formado por relações não significativas ou datas embaralhadas.

As duas validações internas avaliarão o classificador condicionado à rede de relações e aos limites de choque definidos no período de desenvolvimento até outubro de 2025. Como essas etapas anteriores não serão reestimadas dentro de cada divisão, seus resultados não constituirão uma validação temporal ponta a ponta de todo o pipeline. Para isso, seria necessário refazer a seleção das relações, a correção FDR e os limites de choque usando somente o treino de cada divisão. O teste final, por outro lado, permanece isolado: nenhum dado posterior a 31 de outubro de 2025 foi usado para definir a rede, os limites, os atributos ou o modelo que será avaliado entre novembro de 2025 e outubro de 2026.

Até esta etapa, foram concluídos o pré-processamento, a construção das séries, o teste de Granger e a caracterização dos eventos. Os scripts de construção da base, seleção dos classificadores e avaliação final também foram implementados. Entretanto, a base de modelagem ainda precisa ser materializada com os artefatos atuais, e nenhum modelo foi treinado nem avaliado. Após essa execução, as contagens pós-purga deverão substituir as quantidades brutas apresentadas na Tabela 8; somente então

serão acrescentados os resultados comparativos e a avaliação oficial.

Referências

[1] Paul Swuste et al. “Domino effects in chemical factories and clusters: An historical perspective and discussion”. Em: *Process Safety and Environmental Protection* 124 (2019), pp. 18–30. DOI: 10.1016/j.psep.2019.01.015.

[2] C. W. J. Granger. “Investigating Causal Relations by Econometric Models and Cross-spectral Methods”. Em: *Econometrica* 37.3 (1969), pp. 424–438. DOI: 10.2307/1912791.

[3] Kamille Oliveira et al. “Causalidade no preço do tomate no estado do Ceará”. Em: *Contribuciones a Las Ciencias Sociales* 16.10 (2023), pp. 20877–20896. DOI: 10.55905/revconv.16n.10-132.

[4] Yoav Benjamini e Yosef Hochberg. “Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing”. Em: *Journal of the Royal Statistical Society: Series B (Methodological)* 57.1 (1995), pp. 289–300. DOI: 10.1111/j.2517-6161.1995.tb02031.x.