Departamento de Ciência da Computação – UFSJ/DCOMP

MINERAÇÃO DE DADOS APLICADA À DINÂMICA DE PREÇOS NAS CEASAS

Pré-processamento para análise do Efeito Dominó

Autores:

Arthur Henrique Moreira Santos
Gabriel da Silva Souza
Samuel de Souza Carvalho Almeida

Ciência da Computação – UFSJ/DCOMP

São João del-Rei – MG
2026

Sumário

Resumo **1**

1 Introdução **1**

2 Objetivos **2**

2.1 Perguntas de pesquisa 2

2.2 Objetivo geral 2

2.3 Objetivos específicos 2

3 Trabalhos relacionados **2**

4 Caracterização da base de dados **3**

5 Metodologia do pré-processamento **3**

5.1 Ambiente e reprodutibilidade 3

5.2 Seleção e consolidação das cotações 4

5.3 Normalização dos produtos 4

5.4 Tratamento das apresentações e unidades 4

5.5 Conversões inferidas 5

5.6 Exclusões e indicadores de qualidade 5

5.7 Estrutura e validação da saída 5

Referências **5**

Resumo

Este trabalho investiga a dinâmica de preços de produtos agrícolas comercializados em diferentes Centrais de Abastecimento (CEASAs). A primeira etapa da pesquisa concentra-se no Efeito Dominó, entendido como a possibilidade de variações de preço observadas em um mercado contribuírem para antecipar variações posteriores em outro. Os dados utilizados foram coletados por um *crawler* e organizados em um banco SQLite com mais de dois milhões de cotações. Antes da análise temporal, foi desenvolvido um pré-processamento para consolidar versões da mesma cotação, normalizar produtos e apresentações, converter preços para unidades comparáveis quando existem evidências suficientes e registrar limitações sem criar valores artificiais. O processo gera um novo banco SQLite, preserva o banco bruto e mantém indicadores de qualidade, regras de conversão e possíveis *outliers*. Na última execução integral validada, 2.380.608 registros brutos resultaram em 2.372.920 cotações consolidadas. A versão seguinte do processo acrescenta a exclusão de apresentações sem mapeamento confiável e ainda deverá ter suas contagens finais verificadas.

Palavras-chave: CEASA; mineração de dados; séries temporais; pré-processamento; preços agrícolas; Efeito Dominó.

1 Introdução

As CEASAs concentram a comercialização atacadista de produtos agrícolas e produzem cotações que refletem condições de oferta, demanda, sazonalidade, logística e características regionais. Quando observados ao longo do tempo, esses registros permitem investigar se movimentos de preço permanecem locais ou se aparecem posteriormente em outros mercados.

O projeto considera três frentes de investigação: propagação de preços entre mercados, assimetria entre aumentos e reduções e períodos de elevada volatilidade. A etapa atual concentra-se na propagação de preços, denominada Efeito Dominó. As perguntas que orientam essas frentes são apresentadas na Seção de Objetivos.

Uma análise desse tipo exige séries comparáveis. Entretanto, a base contém diferenças de escrita nos produtos, múltiplas formas de apresentação, quantidades expressas em massa ou contagem, intervalos de peso, versões da mesma cotação e valores potencialmente suspeitos. Comparar diretamente os preços originais poderia confundir uma mudança de embalagem com uma variação econômica real.

Diante disso, a primeira entrega do projeto foi a construção de um fluxo de pré-processamento rastreável. Seu objetivo é produzir uma base derivada mais adequada às futuras análises temporais, sem modificar o banco bruto e sem antecipar decisões relativas aos produtos, períodos ou modelos que serão utilizados posteriormente.

O uso do termo Efeito Dominó neste projeto é uma analogia à propagação sequencial descrita em outras áreas. Na segurança de processos, por exemplo, um evento inicial pode produzir consequências sucessivas em outras unidades [1]. Neste trabalho, a propagação investigada não envolve acidentes: corresponde à possível transmissão temporal de informação entre os preços observados em mercados distintos.

2 Objetivos

2.1 Perguntas de pesquisa

O projeto foi organizado a partir das seguintes perguntas:

1. **Efeito Dominó:** usar os preços de outras CEASAs ajuda a prever aumentos de preços em um mercado específico?
2. **Efeito Foguete e Pena:** é possível identificar e prever situações em que os preços sobem mais rápido do que caem entre diferentes CEASAs?
3. **Agrupamento de Volatilidade:** é possível prever períodos de grandes oscilações nos preços de produtos agrícolas comercializados nas CEASAs?

A etapa atual do trabalho concentra-se na primeira pergunta. As demais serão desenvolvidas posteriormente.

2.2 Objetivo geral

Preparar as cotações históricas das CEASAs para a futura investigação do Efeito Dominó entre entrepostos, preservando a rastreabilidade das transformações e evitando conversões sem evidência suficiente.

2.3 Objetivos específicos

- consolidar versões associadas à mesma cotação lógica;
- normalizar diferenças textuais sem misturar automaticamente produtos ou variedades distintas;
- interpretar unidades, embalagens, contagens e intervalos;
- calcular preços por quilograma, unidade-base ou item quando possível;
- identificar registros inadequados para a camada analítica;
- sinalizar possíveis *outliers* sem excluir eventos reais;
- gerar um banco derivado reproduzível e validado.

3 Trabalhos relacionados

Swuste et al. [1] apresentam uma revisão histórica do conceito de efeito dominó em fábricas e agrupamentos da indústria química. Nesse contexto, o fenômeno é caracterizado por uma sequência na qual um evento inicial produz efeitos capazes de atingir outras unidades. Embora o domínio seja

diferente, a noção de propagação espacial e sequencial contribui para delimitar a analogia empregada neste projeto. Aqui, os eventos analisados são movimentos de preço, e não acidentes industriais.

No domínio de preços agrícolas, Oliveira et al. [2] analisaram séries mensais dos tomates Longa Vida e Cajá comercializados em Fortaleza e Ibiapaba, no Ceará, entre janeiro de 2011 e dezembro de 2022. Utilizando causalidade de Granger, o estudo identificou relação bilateral para o tomate Longa Vida e relação unidirecional de Fortaleza para Ibiapaba no caso do tomate Cajá. Esse resultado demonstra a aplicação do teste à transmissão regional de preços de um produto agrícola e fornece uma referência metodológica direta para a primeira pergunta desta pesquisa.

4 Caracterização da base de dados

A base de origem é o arquivo `data/cotacoes.sqlite`, produzido pelo processo de coleta das cotações. O banco relaciona cotações, produtos, apresentações, entrepostos, CEASAs, coletas e proveniências. A origem das observações também permite distinguir os registros coletados diretamente daqueles provenientes do complemento PROHORT.

A última execução integral validada partiu de 2.380.608 cotações. Após a seleção das coletas mais recentes e a consolidação de versões, foram gravadas 2.372.920 cotações no banco derivado. A Tabela 1 resume os principais indicadores observados nessa execução.

Tabela 1: Indicadores da última execução integral validada.

Indicador	**Quantidade**
Cotações no banco bruto	2.380.608
Cotações consolidadas	2.372.920
Versões removidas na consolidação	7.688
Identidades com múltiplas versões	6.423
Apresentações catalogadas	1.941
Cotações com preço comum válido	2.163.137
Cotações com preço comum por kg	1.823.850
Possíveis *outliers* sinalizados	708
Regras de conversão inferida candidatas	69
Regras com critérios estruturais atendidos	49

Fonte: resumo da execução do esquema 6 do pré-processamento.

Essas quantidades descrevem a versão executada antes da exclusão física dos registros com mapeamento insuficiente. Portanto, não representam ainda a contagem final do esquema 7.

5 Metodologia do pré-processamento

5.1 Ambiente e reprodutibilidade

O pré-processamento foi implementado em Python e executado em contêiner Docker. As dependências são gerenciadas pelo `uv`, enquanto o Docker Compose fornece um comando único para construção da

imagem e execução do processo. O banco bruto é aberto somente para leitura, e o resultado é gravado em um novo arquivo, `data/cotacoes_preprocessadas.sqlite`.

A substituição da saída é atômica: o novo banco é construído em um arquivo temporário e somente substitui a versão anterior após a conclusão das validações. Assim, uma falha durante o processamento não sobrescreve uma saída válida nem altera a fonte original.

5.2 Seleção e consolidação das cotações

A identidade lógica de uma cotação representa a combinação de mercado, produto, apresentação e data, sem utilizar o preço como parte de sua definição. Uma mesma identidade pode aparecer em diferentes coletas ou possuir versões simultâneas com preços distintos.

Para cada identidade, o processo seleciona a coleta mais recente registrada na tabela de proveniências. Quando a coleta escolhida contém mais de uma versão, os preços mínimo, comum e máximo são consolidados separadamente pela mediana. Essa regra evita escolher arbitrariamente uma das versões e reduz a influência de um valor isolado. O banco derivado mantém apenas uma linha por identidade e registra a quantidade de versões e a existência de conflito.

5.3 Normalização dos produtos

Os nomes dos produtos recebem uma chave textual sem diferenças de caixa, acentuação, espaços ou pontuação. A descrição original e o identificador do produto continuam preservados. A normalização permite reconhecer grafias equivalentes, mas não junta automaticamente variedades ou classificações que possam apresentar comportamentos de preço diferentes.

Descrições sem conteúdo utilizável, como `*`, recebem o marcador `produto_invalido`. Esses registros permanecem identificáveis no banco, mas não entram na visão analítica principal.

5.4 Tratamento das apresentações e unidades

As apresentações são classificadas segundo sua dimensão: massa, volume, contagem, unidade nativa ou combinação dessas formas. A apresentação original é preservada juntamente com a regra, a fórmula, a evidência e o nível de confiança utilizados na transformação.

Quando o peso total está explícito, a conversão é classificada como `exata`. Quando existem quantidade de itens e peso individual, o peso total é calculado pela multiplicação desses valores e a conversão é `calculada`. Unidades como dúzia e cento são convertidas para 12 e 100 itens, respectivamente, mas não recebem peso em quilogramas sem evidência do peso individual.

Intervalos como `CX 25-28 KG` preservam os limites mínimo e máximo. Um valor central não é criado, pois isso introduziria uma precisão inexistente na fonte. O mesmo princípio é aplicado às apresentações ambíguas: quando não é possível determinar o denominador do preço, a conversão para R$/kg não é realizada.

Também foi tratada uma inconsistência textual específica na qual o sufixo de origem `PE` aparece concatenado à unidade de massa. Dessa forma, `Cx.20 KgPE` é interpretado como 20 kg com o sufixo PE, enquanto `Cx.23 a27KgPE` permanece como intervalo de 23 a 27 kg.

5.5 Conversões inferidas

Apresentações sem peso explícito podem ser comparadas com apresentações que possuem peso declarado para a mesma chave textual de produto, forma de apresentação e origem dos dados. Uma regra somente atende aos critérios estruturais quando candidato e âncora possuem ao menos cinco registros e três datas, e quando todos os pesos explícitos observados concordam.

Os preços não são utilizados para escolher o peso inferido. Essa decisão evita aproximar artificialmente os preços entre CEASAs e produzir o padrão de propagação que a pesquisa pretende investigar. Sem uma data limite definida para a inferência, as regras são apenas registradas como candidatas.

5.6 Exclusões e indicadores de qualidade

Na versão atual do código, cotações que permanecem com os status `sem_unidade`, `sem_quantidade_exata` ou `ambigua` não são gravadas na tabela final. As quantidades excluídas por cada motivo são registradas em `resumo_preprocessamento`, enquanto os dados originais continuam disponíveis no banco bruto.

Preços comuns nulos, iguais a zero ou negativos são marcados como inválidos e ficam fora de `cotacoes_analiticas`. Quando a relação mínimo $\leq$ comum $\leq$ máximo não é respeitada, o preço comum tratado é mantido, mas os limites mínimo e máximo tratados ficam nulos. Essa decisão evita trocar ou ordenar automaticamente valores cuja coluna incorreta não pode ser determinada.

Os possíveis *outliers* são identificados dentro de grupos com o mesmo produto, entreposto e apresentação. Com pelo menos cinco observações, preços por kg inferiores a 0,1 ou superiores a 10 vezes a mediana do grupo são sinalizados. Eles não são removidos automaticamente, pois uma variação extrema pode representar tanto erro quanto um evento econômico relevante.

5.7 Estrutura e validação da saída

O banco derivado contém a tabela principal `cotacoes_preprocessadas`, a visão `cotacoes_analiticas`, o catálogo de apresentações, as regras de conversão, os possíveis *outliers*, o resumo e os parâmetros da execução.

Ao final, são verificadas a integridade interna do SQLite, a unicidade das identidades, a consistência dos marcadores, a cobertura do catálogo e a igualdade entre as quantidades consolidadas, gravadas e excluídas. A versão do esquema 7, que incorpora as exclusões e o tratamento de `KgPE`, está implementada e aguarda uma execução completa para atualização dos indicadores apresentados neste documento.

Referências

[1] Paul Swuste et al. “Domino effects in chemical factories and clusters: An historical perspective and discussion”. Em: *Process Safety and Environmental Protection* 124 (2019), pp. 18–30. DOI: 10.1016/j.psep.2019.01.015.

[2] Kamille Oliveira et al. “Causalidade no preço do tomate no estado do Ceará”. Em: *Contribuciones a Las Ciencias Sociales* 16.10 (2023), pp. 20877–20896. DOI: 10.55905/revconv.16n.10-132.