Departamento de Ciência da Computação – UFSJ/DCOMP

MINERAÇÃO DE DADOS APLICADA À DINÂMICA DE PREÇOS NAS CEASAS

Pré-processamento para análise do Efeito Dominó

Autores:

Arthur Henrique Moreira Santos
Gabriel da Silva Souza
Samuel de Souza Carvalho Almeida

Ciência da Computação – UFSJ/DCOMP

São João del-Rei – MG
2026

Sumário

Resumo **1**

1 Introdução **1**

2 Objetivos **2**

2.1 Perguntas de pesquisa 2

2.2 Objetivo geral 2

2.3 Objetivos específicos 2

3 Trabalhos relacionados **3**

4 Caracterização da base de dados **3**

5 Metodologia **4**

5.1 Fluxo geral 4

5.2 Ambiente e reprodutibilidade 4

5.3 Seleção e consolidação das cotações 4

5.4 Normalização dos produtos 4

5.5 Tratamento das apresentações e unidades 5

5.6 Conversões inferidas 5

5.7 Exclusões e indicadores de qualidade 5

5.8 Estrutura e validação da saída 6

Referências **6**

Resumo

Este trabalho investiga a dinâmica de preços de produtos agrícolas comercializados em diferentes Centrais de Abastecimento (CEASAs). A primeira etapa da pesquisa concentra-se no Efeito Dominó, entendido como a possibilidade de variações de preço observadas em um mercado contribuírem para antecipar variações posteriores em outro. Os dados utilizados foram coletados por um *crawler* e organizados em um banco SQLite com mais de dois milhões de cotações. Antes da análise temporal, foi desenvolvido um pré-processamento para consolidar versões da mesma cotação, normalizar produtos e apresentações, converter preços para unidades comparáveis quando existem evidências suficientes e registrar limitações sem criar valores artificiais. O processo gera um novo banco SQLite, preserva o banco bruto e mantém indicadores de qualidade, regras de conversão e possíveis *outliers*. Na última execução realizada, 2.380.608 registros brutos resultaram em 2.372.920 cotações consolidadas. Após a exclusão de 87.820 registros sem mapeamento suficiente, foram gravadas 2.285.100 cotações no banco derivado, das quais 2.080.417 compõem a camada analítica principal. O pré-processamento da base atual foi concluído; as regras de conversão inferida permanecem candidatas até a definição do período de treino.

Palavras-chave: CEASA; mineração de dados; séries temporais; pré-processamento; preços agrícolas; Efeito Dominó.

1 Introdução

As CEASAs concentram a comercialização atacadista de produtos agrícolas e produzem cotações que refletem condições de oferta, demanda, sazonalidade, logística e características regionais. Quando observados ao longo do tempo, esses registros permitem investigar se movimentos de preço permanecem locais ou se aparecem posteriormente em outros mercados.

O projeto considera três frentes de investigação: propagação de preços entre mercados, assimetria entre aumentos e reduções e períodos de elevada volatilidade. A etapa atual concentra-se na propagação de preços, denominada Efeito Dominó. As perguntas que orientam essas frentes são apresentadas na Seção de Objetivos.

Uma análise desse tipo exige séries comparáveis. Entretanto, a base contém diferenças de escrita nos produtos, múltiplas formas de apresentação, quantidades expressas em massa ou contagem, intervalos de peso, versões da mesma cotação e valores potencialmente suspeitos. Comparar diretamente os preços originais poderia confundir uma mudança de embalagem com uma variação econômica real.

Diante disso, a primeira entrega do projeto foi a construção de um fluxo de pré-processamento rastreável. Seu objetivo é produzir uma base derivada mais adequada às futuras análises temporais, sem modificar o banco bruto e sem antecipar decisões relativas aos produtos, períodos ou modelos que serão utilizados posteriormente.

O uso do termo Efeito Dominó neste projeto é uma analogia à propagação sequencial descrita em outras áreas. Na segurança de processos, por exemplo, um evento inicial pode produzir consequências sucessivas em outras unidades [1]. Neste trabalho, a propagação investigada não envolve acidentes: corresponde à possível transmissão temporal de informação entre os preços observados em mercados

distintos.

2 Objetivos

2.1 Perguntas de pesquisa

O projeto foi organizado a partir das seguintes perguntas:

1. **Efeito Dominó:** usar os preços de outras CEASAs ajuda a prever aumentos de preços em um mercado específico?
2. **Efeito Foguete e Pena:** é possível identificar e prever situações em que os preços sobem mais rápido do que caem entre diferentes CEASAs?
3. **Agrupamento de Volatilidade:** é possível prever períodos de grandes oscilações nos preços de produtos agrícolas comercializados nas CEASAs?

A etapa atual do trabalho concentra-se na primeira pergunta. As demais serão desenvolvidas posteriormente.

2.2 Objetivo geral

Preparar as cotações históricas das CEASAs para a futura investigação do Efeito Dominó entre entrepostos, preservando a rastreabilidade das transformações e evitando conversões sem evidência suficiente.

2.3 Objetivos específicos

- consolidar versões associadas à mesma cotação lógica;
- normalizar diferenças textuais sem misturar automaticamente produtos ou variedades distintas;
- interpretar unidades, embalagens, contagens e intervalos;
- calcular preços por quilograma, unidade-base ou item quando possível;
- identificar registros inadequados para a camada analítica;
- sinalizar e preservar possíveis *outliers*, mantendo-os fora da camada analítica principal sem apagar os valores originais;
- gerar um banco derivado reproduzível e validado.

3 Trabalhos relacionados

Swuste et al. [1] apresentam uma revisão histórica do conceito de efeito dominó em fábricas e agrupamentos da indústria química. Nesse contexto, o fenômeno é caracterizado por uma sequência na qual um evento inicial produz efeitos capazes de atingir outras unidades. Embora o domínio seja diferente, a noção de propagação espacial e sequencial contribui para delimitar a analogia empregada neste projeto. Aqui, os eventos analisados são movimentos de preço, e não acidentes industriais.

No domínio de preços agrícolas, Oliveira et al. [2] analisaram séries mensais dos tomates Longa Vida e Cajá comercializados em Fortaleza e Ibiapaba, no Ceará, entre janeiro de 2011 e dezembro de 2022. Utilizando causalidade de Granger, o estudo identificou relação bilateral para o tomate Longa Vida e relação unidirecional de Fortaleza para Ibiapaba no caso do tomate Cajá. Esse resultado demonstra a aplicação do teste à transmissão regional de preços de um produto agrícola e fornece uma referência metodológica direta para a primeira pergunta desta pesquisa.

4 Caracterização da base de dados

A base de origem é o arquivo `data/cotacoes.sqlite`, produzido pelo processo de coleta das cotações. O banco relaciona cotações, produtos, apresentações, entrepostos, CEASAs, coletas e proveniências. A origem das observações também permite distinguir os registros coletados diretamente daqueles provenientes do complemento PROHORT.

A execução mais recente partiu de 2.380.608 cotações. Após a seleção das coletas mais recentes e a consolidação de versões, foram obtidas 2.372.920 cotações. A exclusão de mapeamentos insuficientes resultou em 2.285.100 cotações gravadas no banco derivado. A Tabela 1 resume os principais indicadores observados nessa execução.

Tabela 1: Indicadores da execução mais recente do pré-processamento.

Indicador	**Quantidade**
Cotações no banco bruto	2.380.608
Cotações consolidadas	2.372.920
Cotações excluídas por mapeamento insuficiente	87.820
Cotações gravadas no banco derivado	2.285.100
Identidades com múltiplas versões mantidas	5.987
Apresentações catalogadas	1.941
Cotações com preço comum válido	2.081.125
Cotações com preço comum por kg	1.824.620
Cotações na camada analítica principal	2.080.417
Outliers desconsiderados da camada principal	708
Regras de conversão inferida candidatas	69
Regras com critérios estruturais atendidos	49

Fonte: resumo da execução mais recente do pré-processamento.

Essas quantidades descrevem a execução concluída para a base atual. Uma nova execução somente produzirá números diferentes se a base de origem ou os critérios configuráveis forem alterados.

5 Metodologia

5.1 Fluxo geral

A Figura 1 apresenta o fluxo geral definido até o momento. As etapas internas da análise de Granger serão detalhadas posteriormente, conforme o desenvolvimento dessa fase do projeto.

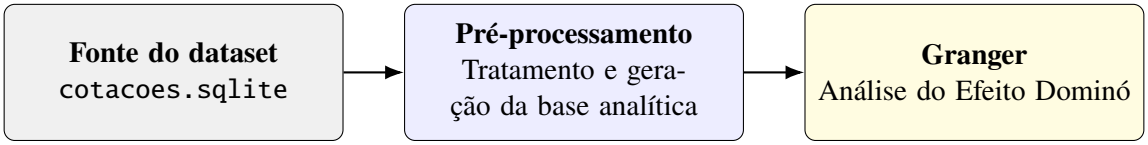


Figura 1: Fluxo geral atual da metodologia.

5.2 Ambiente e reprodutibilidade

O pré-processamento foi implementado em Python e executado em contêiner Docker. As dependências são gerenciadas pelo `uv`, enquanto o Docker Compose fornece um comando único para construção da imagem e execução do processo. O banco bruto é aberto somente para leitura, e o resultado é gravado em um novo arquivo, `data/cotacoes_preprocessadas.sqlite`.

A substituição da saída é atômica: o novo banco é construído em um arquivo temporário e somente substitui a versão anterior após a conclusão das validações. Assim, uma falha durante o processamento não sobrescreve uma saída válida nem altera a fonte original.

5.3 Seleção e consolidação das cotações

A identidade lógica de uma cotação representa a combinação de mercado, produto, apresentação e data, sem utilizar o preço como parte de sua definição. Uma mesma identidade pode aparecer em diferentes coletas ou possuir versões simultâneas com preços distintos.

Para cada identidade, o processo seleciona a coleta mais recente registrada na tabela de proveniências. Quando a coleta escolhida contém mais de uma versão, os preços mínimo, comum e máximo são consolidados separadamente pela mediana. Essa regra evita escolher arbitrariamente uma das versões e reduz a influência de um valor isolado. O banco derivado mantém apenas uma linha por identidade e registra a quantidade de versões e a existência de conflito.

5.4 Normalização dos produtos

Os nomes dos produtos recebem uma chave textual sem diferenças de caixa, acentuação, espaços ou pontuação. A descrição original e o identificador do produto continuam preservados. A normalização permite reconhecer grafias equivalentes, mas não junta automaticamente variedades ou classificações que possam apresentar comportamentos de preço diferentes.

Descrições sem conteúdo utilizável, como `*`, recebem o marcador `produto_invalido`. Esses registros permanecem identificáveis no banco, mas não entram na visão analítica principal.

5.5 Tratamento das apresentações e unidades

As apresentações são classificadas segundo sua dimensão: massa, volume, contagem, unidade nativa ou combinação dessas formas. A apresentação original é preservada juntamente com a regra, a fórmula, a evidência e o nível de confiança utilizados na transformação.

Quando o peso total está explícito, a conversão é classificada como `exata`. Quando existem quantidade de itens e peso individual, o peso total é calculado pela multiplicação desses valores e a conversão é `calculada`. Unidades como dúzia e cento são convertidas para 12 e 100 itens, respectivamente, mas não recebem peso em quilogramas sem evidência do peso individual.

Intervalos como `CX 25-28 KG` preservam os limites mínimo e máximo. Um valor central não é criado, pois isso introduziria uma precisão inexistente na fonte. O mesmo princípio é aplicado às apresentações ambíguas: quando não é possível determinar o denominador do preço, a conversão para R$/kg não é realizada.

Também foi tratada uma inconsistência textual específica na qual o sufixo de origem `PE` aparece concatenado à unidade de massa. Dessa forma, `Cx.20 KgPE` é interpretado como 20 kg com o sufixo PE, enquanto `Cx.23 a27KgPE` permanece como intervalo de 23 a 27 kg.

O parser também reconhece intervalos com hífen antes da unidade, como `Cx.17a18-Kg`, preserva pesos totais explícitos quando o texto contém um intervalo independente de itens e identifica contagens explícitas de unidades ou vasos mesmo quando não existe unidade estruturada na fonte.

5.6 Conversões inferidas

Apresentações sem peso explícito podem ser comparadas com apresentações que possuem peso declarado para a mesma chave textual de produto, forma de apresentação e origem dos dados. Uma regra somente atende aos critérios estruturais quando candidato e âncora possuem ao menos cinco registros e três datas, e quando todos os pesos explícitos observados concordam.

Os preços não são utilizados para escolher o peso inferido. Essa decisão evita aproximar artificialmente os preços entre CEASAs e produzir o padrão de propagação que a pesquisa pretende investigar. Sem uma data limite definida para a inferência, as regras são apenas registradas como candidatas.

5.7 Exclusões e indicadores de qualidade

Na versão atual do código, cotações que permanecem com os status `sem_unidade`, `sem_quantidade_exata` ou `ambigua` não são gravadas na tabela final. As quantidades excluídas por cada motivo são registradas em `resumo_preprocessamento`. As próprias linhas ficam disponíveis em `cotacoes_excluidas_mapeamento`, além de continuarem preservadas no banco bruto.

Preços comuns nulos, iguais a zero ou negativos são marcados como inválidos e ficam fora de `cotacoes_analiticas`. Quando a relação mínimo $\leq$ comum $\leq$ máximo não é respeitada, o preço comum tratado é mantido, mas os limites mínimo e máximo tratados ficam nulos. Essa decisão evita trocar ou ordenar automaticamente valores cuja coluna incorreta não pode ser determinada.

Os possíveis *outliers* são identificados dentro de grupos com o mesmo produto, entreposto e apresentação. Com pelo menos cinco observações, preços por kg inferiores a 0,1 vez ou superiores a

10 vezes a mediana do grupo são sinalizados. Preço comum igual a R$ 0,01 ou razão inferior a 0,01 ou superior a 20 recebe a classificação `erro_provavel`. Entre os demais casos, grupos com pelo menos cinco ocorrências suspeitas recebem `inconsistencia_recorrente`; os restantes são classificados como `extremo_isolado`.

Os valores sinalizados não são apagados nem corrigidos. Eles permanecem na tabela principal e nas visões de auditoria, mas ficam fora de `cotacoes_analiticas_principais`. Assim, não existe uma etapa de revisão manual obrigatória para que a base seja utilizada.

5.8 Estrutura e validação da saída

O banco derivado contém a tabela principal `cotacoes_preprocessadas`, as visões `cotacoes_analiticas` e `cotacoes_analiticas_principais`, a tabela auditável de exclusões, o catálogo de apresentações, as regras de conversão, as classificações de *outliers*, o resumo e os parâmetros da execução.

Ao final, são verificadas a integridade interna do SQLite, a unicidade das identidades, a consistência dos marcadores, a cobertura do catálogo e a igualdade entre as quantidades consolidadas, gravadas e excluídas. A validação também confere a cobertura auditável das exclusões e garante que nenhum *outlier* permaneça na camada analítica principal. Com a execução validada, o pré-processamento da base atual está concluído.

Referências

[1] Paul Swuste et al. “Domino effects in chemical factories and clusters: An historical perspective and discussion”. Em: *Process Safety and Environmental Protection* 124 (2019), pp. 18–30. DOI: 10.1016/j.psep.2019.01.015.

[2] Kamille Oliveira et al. “Causalidade no preço do tomate no estado do Ceará”. Em: *Contribuciones a Las Ciencias Sociales* 16.10 (2023), pp. 20877–20896. DOI: 10.55905/revconv.16n.10-132.