Departamento de Ciência da Computação – UFSJ/DCOMP

MINERAÇÃO DE DADOS APLICADA À DINÂMICA DE PREÇOS NAS CEASAS

Pré-processamento, teste de Granger e caracterização do Efeito Dominó

Autores:

Arthur Henrique Moreira Santos
Gabriel da Silva Souza
Samuel de Souza Carvalho Almeida

Ciência da Computação – UFSJ/DCOMP

São João del-Rei – MG
2026

Sumário

Resumo **1**

1 Introdução **1**

2 Objetivos **2**
2.1 Perguntas de pesquisa 2
2.2 Objetivo geral 2
2.3 Objetivos específicos 2

3 Trabalhos relacionados **3**

4 Caracterização da base de dados **3**

5 Metodologia **4**
5.1 Visão geral do fluxo 4
5.2 Ambiente e reprodutibilidade 4
5.3 Política de retenção dos dados do crawler 4
5.4 Tipos de decisão sobre um registro 5
5.5 Seleção e consolidação das cotações 6
5.6 Normalização dos produtos 6
5.7 Tratamento das apresentações e unidades 6
5.8 Conversões inferidas 7
5.9 Exclusões e indicadores de qualidade 7
5.10 Estrutura e validação da saída 8

6 Construção das séries temporais **9**
6.1 Recorte e critérios de entrada 9
6.2 Agregação, preenchimento e retornos 9

7 Teste de causalidade de Granger **10**
7.1 Formação e qualificação dos pares 10
7.2 Diagnóstico de estacionariedade 10
7.3 Especificação, seleção de lags e significância 11
7.4 Validação e rastreabilidade 11

8 Resultados atuais **12**
8.1 Síntese quantitativa 12
8.2 Interpretação e limitações 12

9 Caracterização do Efeito Dominó **12**
9.1 Relações analisadas e definição de choque 12
9.2 Classificação dos eventos 13

9.3 Rastreabilidade, resultados e limitações 14

Referências **16**

Resumo

Este trabalho investiga a dinâmica de preços de produtos agrícolas comercializados em diferentes Centrais de Abastecimento (CEASAs). A etapa atual concentra-se no Efeito Dominó, entendido como a possibilidade de movimentos de preço observados em um entreposto contribuírem para antecipar movimentos posteriores em outro. Os dados foram coletados por um *crawler* e organizados em um banco SQLite com mais de dois milhões de cotações. O fluxo executado até o momento compreende a preservação do banco bruto, o pré-processamento das cotações, a construção de séries temporais comparáveis, o teste de causalidade de Granger e a caracterização do Efeito Dominó. Na execução encadeada documentada, 2.362.506 registros brutos resultaram em 2.272.103 cotações no banco derivado, das quais 1.814.153 possuem preço comum em R$/kg. O recorte temporal carregou 174.687 cotações e produziu 252 pares candidatos entre mercados. Dos 134 pares elegíveis, todos atenderam aos critérios de estacionariedade; foram testadas 268 direções e 62 apresentaram significância após a correção de Benjamini–Hochberg. Esses resultados são preliminares e representam evidência de precedência temporal e capacidade preditiva no sentido de Granger, não uma demonstração isolada de causalidade econômica direta. Nas 62 relações significativas foram encontrados 6.138 choques na origem; 4.807 puderam ser classificados e 1.881 apresentaram resposta no destino dentro da janela de cinco dias úteis.

Palavras-chave: CEASA; mineração de dados; séries temporais; pré-processamento; preços agrícolas; Efeito Dominó.

1 Introdução

As CEASAs concentram a comercialização atacadista de produtos agrícolas e produzem cotações que refletem condições de oferta, demanda, sazonalidade, logística e características regionais. Quando observados ao longo do tempo, esses registros permitem investigar se movimentos de preço permanecem locais ou se aparecem posteriormente em outros mercados.

O projeto considera três frentes de investigação: propagação de preços entre mercados, assimetria entre aumentos e reduções e períodos de elevada volatilidade. A etapa atual concentra-se na propagação de preços, denominada Efeito Dominó. As perguntas que orientam essas frentes são apresentadas na Seção de Objetivos.

Uma análise desse tipo exige séries comparáveis. Entretanto, a base contém diferenças de escrita nos produtos, múltiplas formas de apresentação, quantidades expressas em massa ou contagem, intervalos de peso, versões da mesma cotação e valores potencialmente suspeitos. Comparar diretamente os preços originais poderia confundir uma mudança de embalagem com uma variação econômica real.

Diante disso, foi construído um fluxo rastreável que parte do banco produzido pelo *crawler*, gera uma base pré-processada, organiza séries temporais, aplica o teste de Granger e caracteriza ocorrências de Efeito Dominó. O banco bruto não é modificado e cada etapa gera uma saída derivada auditável. Até o momento, não foi realizado o treinamento de um modelo preditivo: essa fase será definida a partir da base de eventos caracterizados.

O uso do termo Efeito Dominó neste projeto é uma analogia à propagação sequencial descrita em

outras áreas. Na segurança de processos, por exemplo, um evento inicial pode produzir consequências sucessivas em outras unidades [1]. Neste trabalho, a propagação investigada não envolve acidentes: corresponde à possível transmissão temporal de informação entre os preços observados em mercados distintos.

2 Objetivos

2.1 Perguntas de pesquisa

O projeto foi organizado a partir das seguintes perguntas:

1. **Efeito Dominó:** usar os preços de outras CEASAs ajuda a prever aumentos de preços em um mercado específico?
2. **Efeito Foguete e Pena:** é possível identificar e prever situações em que os preços sobem mais rápido do que caem entre diferentes CEASAs?
3. **Agrupamento de Volatilidade:** é possível prever períodos de grandes oscilações nos preços de produtos agrícolas comercializados nas CEASAs?

A etapa atual do trabalho concentra-se na primeira pergunta. As demais serão desenvolvidas posteriormente.

2.2 Objetivo geral

Preparar e analisar as cotações históricas das CEASAs para investigar a existência de influência temporal entre entrepostos no sentido de Granger, preservando a rastreabilidade das transformações e evitando conversões sem evidência suficiente.

2.3 Objetivos específicos

- consolidar versões associadas à mesma cotação lógica;
- normalizar diferenças textuais sem misturar automaticamente produtos ou variedades distintas;
- interpretar unidades, embalagens, contagens e intervalos;
- calcular preços por quilograma, unidade-base ou item quando possível;
- identificar registros inadequados para a camada analítica;
- sinalizar e preservar possíveis *outliers*, mantendo-os fora da camada analítica principal sem apagar os valores originais;
- gerar um banco derivado reproduzível e validado;

- construir séries diárias comparáveis por produto e entreposto;
- verificar a estacionariedade das séries de retornos;
- testar a precedência temporal entre pares de entrepostos por meio da causalidade de Granger;
- caracterizar ocorrências de Efeito Dominó nas relações significativas.

3 Trabalhos relacionados

Swuste et al. [1] apresentam uma revisão histórica do conceito de efeito dominó em fábricas e agrupamentos da indústria química. Nesse contexto, o fenômeno é caracterizado por uma sequência na qual um evento inicial produz efeitos capazes de atingir outras unidades. Embora o domínio seja diferente, a noção de propagação espacial e sequencial contribui para delimitar a analogia empregada neste projeto. Aqui, os eventos analisados são movimentos de preço, e não acidentes industriais.

O teste proposto por Granger [2] verifica se valores passados de uma série acrescentam informação à previsão de outra série, além da informação já contida no próprio histórico da variável prevista. Portanto, a expressão causalidade de Granger indica precedência temporal com ganho preditivo e não, isoladamente, um mecanismo econômico causal.

No domínio de preços agrícolas, Oliveira et al. [3] analisaram séries mensais dos tomates Longa Vida e Cajá comercializados em Fortaleza e Ibiapaba, no Ceará, entre janeiro de 2011 e dezembro de 2022. Utilizando causalidade de Granger, o estudo identificou relação bilateral para o tomate Longa Vida e relação unidirecional de Fortaleza para Ibiapaba no caso do tomate Cajá. Esse resultado demonstra a aplicação do teste à transmissão regional de preços de um produto agrícola e fornece uma referência metodológica direta para a primeira pergunta desta pesquisa.

4 Caracterização da base de dados

A base de origem é o arquivo `data/cotacoes.sqlite`, produzido pelo processo de coleta das cotações. O banco relaciona cotações, produtos, apresentações, entrepostos, CEASAs, coletas e proveniências. A origem das observações também permite distinguir os registros coletados diretamente daqueles provenientes do complemento PROHORT.

A execução encadeada documentada partiu de um retrato com 2.362.506 cotações. Após a seleção das coletas mais recentes e a consolidação de versões, foram obtidas 2.355.195 identidades. A exclusão de mapeamentos insuficientes resultou em 2.272.103 cotações gravadas no banco derivado. A Tabela 1 resume os principais indicadores observados nessa execução.

Essas quantidades descrevem o retrato ligado aos bancos de Granger e Efeito Dominó consultados. Como o crawler pode continuar acrescentando cotações, uma nova execução pode produzir números diferentes mesmo sem alteração dos critérios.

Tabela 1: Indicadores da execução encadeada documentada do pré-processamento.

Indicador	**Quantidade**
Cotações no retrato do banco bruto	2.362.506
Linhas associadas às últimas coletas	2.362.001
Identidades consolidadas	2.355.195
Cotações excluídas por mapeamento insuficiente	83.092
Cotações gravadas no banco derivado	2.272.103
Identidades com múltiplas versões	5.813
Apresentações catalogadas	1.931
Cotações com preço comum válido	2.068.289
Cotações com preço comum por kg	1.814.153
Cotações na camada analítica principal	2.067.591
Outliers desconsiderados da camada principal	698
Regras de conversão inferida aplicadas	13
Cotações com conversão inferida	3.250

Fonte: resumo do banco pré-processado ligado aos resultados documentados.

5 Metodologia

5.1 Visão geral do fluxo

A Figura 1 apresenta as etapas concluídas até a caracterização do Efeito Dominó. Cada banco derivado preserva a origem e os parâmetros de sua execução, permitindo reproduzir o caminho entre a coleta e os resultados estatísticos.

5.2 Ambiente e reprodutibilidade

O pré-processamento foi implementado em Python e executado em contêiner Docker. As dependências são gerenciadas pelo `uv`, enquanto o Docker Compose fornece um comando único para construção da imagem e execução do processo. O banco bruto é aberto somente para leitura, e o resultado é gravado em um novo arquivo, `resultados/preprocessamento/cotacoes_preprocessadas.sqlite`.

A substituição da saída é atômica: o novo banco é construído em um arquivo temporário e somente substitui a versão anterior após a conclusão das validações. Assim, uma falha durante o processamento não sobrescreve uma saída válida nem altera a fonte original.

Essa garantia é aplicada separadamente a cada etapa. O pipeline executa pré-processamento, Granger e Efeito Dominó em sequência, mas não confirma os três bancos em uma transação única. Se uma etapa posterior falhar, uma saída anterior já concluída pode ter sido atualizada, enquanto os bancos antigos das etapas seguintes permanecem preservados. A compatibilidade da cadeia é verificada pelos hashes, identificadores de execução e parâmetros registrados em cada artefato.

5.3 Política de retenção dos dados do crawler

O banco derivado não é uma cópia integral do banco do crawler. A seleção dos campos separa atributos da observação, informações necessárias para auditoria e estado operacional do coletor. As

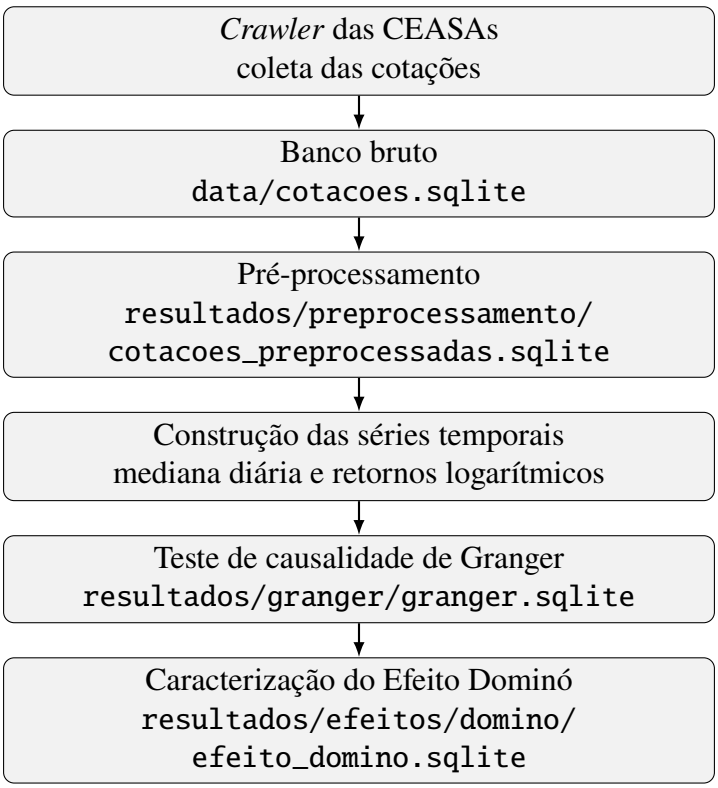


Figura 1: Fluxo metodológico executado até a caracterização do Efeito Dominó.

tabelas `backfill_states` e `schema_migrations` e campos como cursor, erro, caminho e hash do arquivo bruto e chaves internas de ocorrência permanecem somente no banco de origem. Eles descrevem o funcionamento da coleta, e não o preço, o produto, o mercado, a data ou a apresentação observada. Repeti-los na tabela analítica aumentaria a redundância e poderia confundi-los com variáveis econômicas.

Por outro lado, são preservados o identificador e as datas da coleta, os identificadores e nomes das dimensões, os textos originais do produto e da apresentação e os campos do complemento PROHORT. Esses dados permitem localizar a proveniência, interpretar a unidade original e distinguir informações diretas daquelas incorporadas pelo complemento. Portanto, os metadados operacionais não foram apagados: apenas permanecem na fonte, que continua sendo a camada de auditoria integral.

A tabela `cotacao_proveniencias` também não é copiada linha a linha. Como uma cotação pode estar ligada a mais de uma coleta, uma junção direta multiplicaria observações. Ela é usada para selecionar a coleta mais recente e para confirmar a proveniência, sem transformar registros de rastreamento em novas cotações.

5.4 Tipos de decisão sobre um registro

Neste trabalho, exclusão e filtro não são sinônimos. Foram adotadas quatro formas de tratamento:

- **preservação**: o valor original ou sua proveniência permanece disponível;
- **consolidação**: várias versões da mesma identidade passam a representar uma única observação;

- **exclusão da tabela final**: a linha não entra em `cotacoes_preprocessadas`, mas permanece no banco bruto e em `cotacoes_excluidas_mapeamento`;
- **desconsideração analítica**: a linha continua no banco derivado, porém não participa de uma visão ou teste cujos requisitos não atende.

Essa taxonomia evita interpretar "não usado em Granger" como "apagado do banco".

5.5 Seleção e consolidação das cotações

A identidade lógica é representada por `chave_identidade`, fornecida pelo banco do crawler. O projeto de mineração trata essa chave como contrato de entrada e não a recalcula. Uma mesma identidade pode aparecer em diferentes coletas ou possuir versões simultâneas com preços distintos.

Para cada identidade, o processo seleciona a coleta mais recente registrada na tabela de proveniências. A ordenação usa a data de download, a data de processamento e, como desempate, o maior identificador da coleta. Quando a linha não está associada à coleta escolhida para sua identidade, ela permanece somente no histórico do banco bruto e não segue para a consolidação. Quando a coleta escolhida contém mais de uma versão, os preços mínimo, comum e máximo são consolidados separadamente pela mediana. A situação de mercado somente é mantida quando as versões concordam; em caso de conflito, fica nula. Essa regra evita escolher arbitrariamente uma versão e reduz a influência de um valor isolado. O banco derivado mantém uma linha por identidade e registra a quantidade de versões e a existência de conflito.

5.6 Normalização dos produtos

Os nomes dos produtos recebem uma chave textual sem diferenças de caixa, acentuação, espaços ou pontuação. A descrição original e o identificador do produto continuam preservados. A normalização permite reconhecer grafias equivalentes, mas não junta automaticamente variedades ou classificações que possam apresentar comportamentos de preço diferentes.

A regra remove espaços nas extremidades, ignora caixa, decompõe caracteres Unicode, retira acentos, substitui sequências não alfanuméricas por espaços e reduz espaços repetidos. O nome normalizado do banco tem prioridade; o alias original é usado apenas quando a primeira opção está vazia. Termos de variedade não são removidos, de forma que, por exemplo, pimentão e pimentão verde permanecem chaves distintas.

Descrições sem conteúdo utilizável, como `*`, recebem o marcador `produto_invalido`. Esses registros permanecem identificáveis no banco, mas não entram na visão analítica principal.

5.7 Tratamento das apresentações e unidades

As apresentações são classificadas segundo sua dimensão: massa, volume, contagem, unidade nativa ou combinação dessas formas. A apresentação original é preservada juntamente com a regra, a fórmula, a evidência e o nível de confiança utilizados na transformação.

Quando o peso total está explícito, a conversão é classificada como `exata`. Quando existem quantidade de itens e peso individual, o peso total é calculado pela multiplicação desses valores e a conversão é `calculada`. Unidades como dúzia e cento são convertidas para 12 e 100 itens, respectivamente, mas não recebem peso em quilogramas sem evidência do peso individual.

Volumes são preservados em litros, mas não convertidos para quilogramas porque a fonte não informa a densidade. Unidades nativas também são mantidas em sua própria base. O critério geral é somente criar R$/kg quando o denominador pode ser obtido de forma determinística ou por uma regra inferida que atenda a todos os controles descritos a seguir.

Intervalos como `CX 25-28 KG` preservam os limites mínimo e máximo. Um valor central não é criado, pois isso introduziria uma precisão inexistente na fonte. O mesmo princípio é aplicado às apresentações ambíguas: quando não é possível determinar o denominador do preço, a conversão para R$/kg não é realizada.

Também foi tratada uma inconsistência textual específica na qual o sufixo de origem `PE` aparece concatenado à unidade de massa. Dessa forma, `Cx.20 KgPE` é interpretado como 20 kg com o sufixo PE, enquanto `Cx.23 a27KgPE` permanece como intervalo de 23 a 27 kg.

O parser também reconhece intervalos com hífen antes da unidade, como `Cx.17a18-Kg`, preserva pesos totais explícitos quando o texto contém um intervalo independente de itens e identifica contagens explícitas de unidades ou vasos mesmo quando não existe unidade estruturada na fonte.

5.8 Conversões inferidas

Apresentações sem peso explícito podem ser comparadas com apresentações que possuem peso declarado para a mesma chave textual de produto, assinatura da apresentação e origem dos dados. A assinatura normaliza o texto e remove apenas termos de massa. Uma regra somente atende aos critérios estruturais quando candidato e âncora possuem ao menos cinco identidades e três datas, quando todos os pesos explícitos observados concordam e quando a data limite do treino foi informada.

Os preços não são utilizados para escolher o peso inferido. Essa decisão evita aproximar artificialmente os preços entre CEASAs e produzir o padrão de propagação que a pesquisa pretende investigar. Para impedir que informações futuras participem da criação das regras, a data limite de inferência foi fixada em 31 de outubro de 2025, a mesma data de corte do conjunto de treino. Somente registros com entreposto definido e preço comum positivo contam como suporte, mas o valor desse preço não participa da escolha do peso. Na execução documentada, 13 regras foram aplicadas a 3.250 cotações; outras 11 regras permaneceram apenas como candidatas por não atenderem a todos os critérios definidos.

5.9 Exclusões e indicadores de qualidade

Na versão atual do código, cotações que permanecem com os status `sem_unidade`, `sem_quantidade_exata` ou `ambigua` não são gravadas na tabela final. As quantidades excluídas por cada motivo são registradas em `resumo_preprocessamento`. As próprias linhas ficam disponíveis em `cotacoes_excluidas_mapeamento`, além de continuarem preservadas no banco bruto.

Na execução documentada, as 83.092 exclusões foram compostas por 83.082 registros sem unidade, nove sem quantidade exata e um ambíguo. Essa distribuição é registrada para permitir que uma futura ampliação do parser seja avaliada pelo tipo de informação que ainda falta.

Apresentações ausentes, intervalos, volumes e unidades nativas não são automaticamente excluídos. Elas permanecem na tabela final com marcadores e somente ficam fora de análises que exigem uma massa total exata. Essa decisão preserva dados que ainda podem ser úteis em comparações na unidade original e evita tratar toda indisponibilidade de R$/kg como erro de coleta.

Preços comuns nulos, iguais a zero ou negativos são marcados como inválidos e ficam fora de `cotacoes_analiticas`. Quando a relação mínimo $\leq$ comum $\leq$ máximo não é respeitada, o preço comum tratado é mantido, mas os limites mínimo e máximo tratados ficam nulos. Essa decisão evita trocar ou ordenar automaticamente valores cuja coluna incorreta não pode ser determinada.

Os possíveis *outliers* são identificados dentro de grupos com o mesmo produto, entreposto e apresentação. Com pelo menos cinco observações, preços por kg inferiores a 0,1 vez ou superiores a 10 vezes a mediana do grupo são sinalizados. Preço comum igual a R$ 0,01 ou razão inferior a 0,01 ou superior a 20 recebe a classificação `erro_provavel`. Entre os demais casos, grupos com pelo menos cinco ocorrências suspeitas recebem `inconsistencia_recorrente`; os restantes são classificados como `extremo_isolado`.

Entre os 698 casos sinalizados na execução documentada, 169 foram classificados como erro provável, 438 como inconsistência recorrente e 91 como extremo isolado.

Os valores sinalizados não são apagados nem corrigidos. Eles permanecem na tabela principal e nas visões de auditoria, mas ficam fora de `cotacoes_analiticas_principais`. Assim, não existe uma etapa de revisão manual obrigatória para que a base seja utilizada.

A etapa de Granger desconsidera todas as três classes de suspeita, e não apenas `erro_provavel`. O motivo é que não houve revisão externa capaz de separar um extremo econômico real de uma falha de denominador. A cotação continua disponível para que essa decisão possa ser revista futuramente.

A Tabela 2 resume a diferença entre exclusão e desconsideração analítica.

Tabela 2: Destino dos registros conforme a regra de qualidade.

Condição	**Destino**	**Critério e motivo**
Sem unidade, sem quantidade exata ou ambígua	Banco bruto e tabela de exclusões	Não existe denominador identificável com segurança; a linha não entra na tabela final, mas permanece auditável.
Sem apresentação, intervalo, volume ou unidade nativa	Tabela final com marcador	O dado pode ser útil em sua unidade original; somente fica fora de análises que exigem massa total exata.
Produto, preço comum ou dimensão inválida	Tabela final, fora da visão analítica	Falta uma dimensão essencial para interpretar a observação.
Outlier suspeito	Tabela final e visão de auditoria	O valor não é corrigido, mas não participa de Granger sem revisão externa.
Conversão incerta	Tabela final, fora de Granger	A comparação entre mercados exige preço em uma unidade comum.

5.10 Estrutura e validação da saída

O banco derivado contém a tabela principal `cotacoes_preprocessadas`, as visões `cotacoes_analiticas` e `cotacoes_analiticas_principais`, a tabela auditável de exclusões, o catálogo

de apresentações, as regras de conversão, as classificações de *outliers*, o resumo e os parâmetros da execução.

Ao final, são verificadas a integridade interna do SQLite, a unicidade das identidades, a consistência dos marcadores, a cobertura do catálogo e a igualdade entre as quantidades consolidadas, gravadas e excluídas. A validação também confere a cobertura auditável das exclusões e garante que nenhum *outlier* permaneça na camada analítica principal. Essas verificações foram concluídas para o artefato de pré-processamento ligado aos resultados apresentados.

6 Construção das séries temporais

6.1 Recorte e critérios de entrada

O recorte atual considera 12 produtos e sete entrepostos: Recife, Grande Vitória, Curitiba, Maringá, Cascavel, Foz do Iguaçu e Londrina. Foram utilizadas cotações entre 4 de janeiro de 2022 e 31 de outubro de 2026, desde que possuam preço comum válido em R$/kg, não estejam sinalizadas como *outlier* e tenham conversão exata, calculada, padronizada ou inferida com alta confiança. O período até 31 de outubro de 2025 foi destinado à construção e ao diagnóstico das séries; o intervalo posterior foi preservado para avaliações futuras.

Antes dessa seleção, o programa exige que o banco pré-processado tenha uma execução concluída e que o limite temporal usado para inferir pesos seja igual ao fim do treino. Quando a origem bruta ainda está disponível, ela também não pode ser mais recente que o banco derivado. A etapa é interrompida se um dos sete mercados estiver ausente ou associado a mais de uma CEASA ou UF. Essas regras impedem a combinação de dados novos com conversões antigas, o uso de informação futura e a junção de mercados ambíguos.

Os sete entrepostos foram definidos na exploração anterior aos testes porque apresentavam mais de mil datas, cobertura multi-anual atual e sobreposição a partir de janeiro de 2022. Os outros 15 entrepostos do banco não foram removidos da base derivada: ficaram fora deste recorte por terem menos de mil datas, série encerrada antes do período ou coleta recente e curta.

Os 12 produtos formam uma cesta de interesse fixada na exploração inicial: batata, tomate, cebola, cenoura, morango, beterraba, melão, pimentão verde, pimentão, batata-doce, banana-prata e quiabo. A lista não foi determinada pelos p-valores e não corresponde a um ranking automático. A cobertura efetiva de cada combinação produto–mercados é verificada posteriormente, o que evita que a seleção substantiva substitua o critério amostral.

6.2 Agregação, preenchimento e retornos

Quando existe mais de uma cotação para o mesmo produto, entreposto e data, utiliza-se a mediana diária do preço comum em R$/kg. Fins de semana são desconsiderados e falhas curtas podem ser preenchidas pelo último valor observado por, no máximo, três dias úteis consecutivos. Lacunas maiores permanecem abertas para não criar continuidade artificial. Em seguida, os preços são transformados em retornos logarítmicos diários:

$$r_t = \ln(P_t) - \ln(P_{t-1}), \tag{1}$$

em que P_t representa a mediana diária do preço. Essa transformação direciona a análise às variações relativas, reduzindo o efeito dos diferentes níveis de preço entre mercados.

São materializadas as 84 combinações entre 12 produtos e sete mercados, inclusive as combinações sem dados. Cada ponto recebe um marcador que distingue cotação realmente observada de valor preenchido. Depois do terceiro dia útil sem observação, inicia-se uma lacuna e a sequência seguinte recebe outro segmento. O retorno somente é calculado entre preços disponíveis no mesmo segmento; portanto, uma lacuna não pode produzir um retorno ou uma defasagem artificial. Os valores preenchidos auxiliam o alinhamento dos calendários, mas não contam para admitir um par nem podem iniciar ou confirmar um evento de Efeito Dominó.

Na execução documentada, o recorte carregou 174.687 cotações, desconsiderou 320 registros de fim de semana e produziu 63.011 pontos diários observados e 8.529 pontos preenchidos. Nenhuma cotação inferida entrou nesse recorte específico.

7 Teste de causalidade de Granger

7.1 Formação e qualificação dos pares

Para cada produto, foram formados todos os pares possíveis entre os sete entrepostos, totalizando 252 pares candidatos. Um par somente é elegível quando as duas séries possuem ao menos 400 dias úteis observados em comum no período de treino. Pontos preenchidos não contam para esse limite. Pares sem observação recebem `serie_ausente`; os demais pares abaixo do limite recebem `dias_observados_insuficientes`. Todos permanecem registrados com o motivo. O limite corresponde a aproximadamente um ano e meio de dias úteis e evita estimar regressões com uma sobreposição curta. Além dos dias observados, registra-se a sobreposição disponível com preenchimento, mas ela não decide a elegibilidade. Nos pares aprovados, os retornos são recalculados em segmentos comuns, que são interrompidos por uma lacuna em qualquer uma das séries. Os retornos são então avaliados pelos testes ADF e KPSS; o par segue para Granger apenas quando as duas séries atendem simultaneamente aos critérios de estacionariedade.

7.2 Diagnóstico de estacionariedade

Os diagnósticos usam o maior segmento contínuo do par. Cada série deve conter ao menos 30 retornos, não ser constante, apresentar ADF com $p < 0{,}05$ e KPSS com $p > 0{,}05$. Exigir concordância dos dois testes reduz a dependência de uma única hipótese nula. O ADF usa constante e escolhe internamente suas defasagens pelo BIC; o KPSS usa constante e seleção automática de defasagens. Amostra insuficiente, série constante ou erro numérico reprova o par e mantém o motivo no banco. As duas direções recebem `nao_estacionario` e não participam da correção de múltiplos testes.

7.3 Especificação, seleção de lags e significância

As duas direções de cada par são testadas separadamente. São avaliadas de uma a dez defasagens em uma amostra fixa, e a quantidade de defasagens é escolhida pelo Critério de Informação Bayesiano (BIC). O teste F verifica se os valores passados da série de origem acrescentam informação à previsão da série de destino. Como várias hipóteses são avaliadas, os valores p recebem correção global de Benjamini–Hochberg, com taxa de falsas descobertas de 5% [4].

Para uma direção $A \to B$ e um lag p, o modelo restrito contém apenas o passado do destino:

$$r_t^B = c + \sum_{i=1}^{p} \phi_i r_{t-i}^B + \varepsilon_t, \tag{2}$$

enquanto o modelo irrestrito acrescenta o passado da origem:

$$r_t^B = c + \sum_{i=1}^{p} \phi_i r_{t-i}^B + \sum_{i=1}^{p} \beta_i r_{t-i}^A + \varepsilon_t. \tag{3}$$

O teste F compara esses modelos. Matriz sem posto completo, amostra insuficiente ou resíduo nulo produz `erro_modelo`, e não um valor p artificial.

A amostra de todos os lags começa depois da décima defasagem, mesmo quando o modelo avaliado usa menos lags. Isso impede que o BIC favoreça um modelo apenas por ter recebido mais observações. Segmentos separados por lacunas não são concatenados e, em caso de empate no BIC, escolhe-se o menor lag. Todos os dez resultados são preservados, mas somente o valor p do lag escolhido em cada direção com status `testado` participa da correção global. A aprovação principal exige $q < 0{,}05$; significância apenas no valor p bruto não envia a relação para o Efeito Dominó.

Um resultado significativo é interpretado como evidência de influência temporal preditiva no sentido de Granger. Ele não prova, sozinho, que um entreposto provoque diretamente a alteração de preço no outro, pois fatores externos ou variáveis não observadas também podem explicar a relação.

7.4 Validação e rastreabilidade

O banco de Granger registra o caminho, o tamanho e o hash SHA-256 do banco pré-processado, o identificador da execução de origem e todos os parâmetros do recorte. Também preserva as séries, os pares rejeitados e seus motivos, os diagnósticos de estacionariedade, os resultados de todos os lags e os coeficientes do modelo escolhido.

Antes da substituição do arquivo anterior, são verificadas a integridade do SQLite e suas chaves estrangeiras, a aplicação do limite mínimo de cobertura, a presença das duas direções para cada par elegível, os dez resultados de lag para cada direção testada, a seleção de um lag entre 1 e 10 e a permanência dos valores q no intervalo de zero a um. Essas verificações confirmam a coerência interna do artefato, mas não transformam associação temporal em causalidade econômica.

8 Resultados atuais

8.1 Síntese quantitativa

A Tabela 3 resume a execução documentada. Dos 252 pares candidatos, 134 atenderam ao mínimo de sobreposição e todos passaram pelos diagnósticos de estacionariedade. Isso produziu 268 direções testadas, das quais 80 seriam significativas sem ajuste e 62 permaneceram significativas após a correção global.

Tabela 3: Resumo dos resultados atuais do teste de Granger.

Indicador	**Quantidade**
Cotações carregadas no recorte	174.687
Pares candidatos	252
Pares com série ausente	53
Pares com cobertura observada insuficiente	65
Pares elegíveis e estacionários	134
Direções testadas	268
Direções significativas sem correção	80
Direções significativas após correção FDR	62
Pares com ao menos uma direção significativa	50
Relações unidirecionais	38
Relações bidirecionais	12

Fonte: banco `resultados/granger/granger.sqlite` da execução documentada.

8.2 Interpretação e limitações

Os resultados mostram, no recorte analisado, evidências de influência temporal entre determinados entrepostos. Tomate, batata e morango concentraram, respectivamente, 14, 13 e 11 direções significativas. Curitiba e Maringá foram as origens mais frequentes entre as relações significativas, com 18 e 15 direções. Esses números são preliminares e poderão mudar caso sejam alterados o período, os produtos, os mercados ou a definição operacional do Efeito Dominó.

Até esta etapa, o trabalho demonstrou a existência de relações preditivas no sentido de Granger dentro do recorte estudado. O treinamento de modelos ainda não foi realizado. A seção seguinte apresenta a definição operacional adotada para localizar ocorrências de Efeito Dominó antes da futura modelagem.

9 Caracterização do Efeito Dominó

9.1 Relações analisadas e definição de choque

O resultado de Granger é utilizado como um mapa das relações que devem ser observadas, e não como um modelo de previsão. Para cada produto, somente as direções que permaneceram significativas após a correção FDR são examinadas. Em seguida, as séries são percorridas cronologicamente para

localizar uma alta no mercado de origem e verificar se ela foi seguida por uma alta no mercado de destino.

Uma alta é considerada forte quando supera simultaneamente 5% e o percentil 90 dos retornos daquele produto e entreposto. O percentil é calculado apenas com o período de treino, impedindo que dados do período de teste influenciem a regra. Tanto o movimento inicial quanto a resposta são determinados por cotações realmente observadas; valores preenchidos para cobrir falhas curtas não podem iniciar nem confirmar um evento.

Como os retornos são logarítmicos, o piso de 5% é representado por $\ln(1 + 0{,}05)$. Para cada produto e mercado, o limite usado é

$$L = \max\left\{\ln(1 + 0{,}05),\ Q_{0,90}(r_{\text{treino,obs}})\right\}. \tag{4}$$

O limite é próprio de cada produto e mercado, em vez de um valor único para toda a base, porque a distribuição das variações difere entre séries. O piso de 5% evita classificar como choque uma variação pequena em uma série estável; o percentil 90 adapta a exigência quando a volatilidade histórica é maior.

9.2 Classificação dos eventos

Para uma relação direcionada $A \rightarrow B$, a caracterização segue os passos abaixo:

1. localizar uma alta forte do produto no entreposto A;
2. confirmar que existe uma cotação observada em B na mesma data;
3. desconsiderar como propagação os casos em que A e B já apresentam uma alta forte simultaneamente;
4. observar as cotações de B nos cinco dias úteis seguintes, sem atravessar a divisão entre treino e teste;
5. registrar Efeito Dominó quando a alta acumulada em B atingir o limite calculado para sua própria série, usando como base o preço observado em B na data inicial.

Quando existe ao menos uma cotação futura observada no destino, mas a resposta não ocorre dentro da janela, o caso é marcado como não propagado. Casos sem cotação inicial no destino, sem nenhuma observação posterior ou com movimento simultâneo são preservados para auditoria, mas não recebem rótulo positivo ou negativo. Essa distinção evita transformar ausência de dados em ausência de propagação. A resposta registrada é a primeira data observada em que a alta acumulada atinge o limite, e não necessariamente a data da maior alta na janela.

A Tabela 4 explicita a decisão atribuída a cada condição. A janela pode conter menos de cinco cotações: uma única observação futura já permite o rótulo negativo se o limite não for atingido; somente a ausência total de observações futuras representa falta de cobertura.

A unidade resultante representa um produto, uma origem, um destino e a data da alta inicial. Assim, a nova base indicará explicitamente os casos em que a propagação foi observada e aqueles em

Tabela 4: Regras de classificação dos candidatos ao Efeito Dominó.

Condição	Rótulo	Decisão
Cotação futura observada atinge o limite	1	`confirmado`; registra a primeira resposta.
Cotação futura existe, mas não atinge o limite	0	`nao_confirmado`; houve cobertura para testar a regra.
Destino também supera seu limite na data inicial	Nulo	`movimento_simultaneo`; não há propagação posterior.
Destino sem base observada ou com preço-base inválido	Nulo	Não existe referência comparável para calcular a alta acumulada.
Nenhuma cotação futura observada na janela	Nulo	`sem_cobertura_destino`; falta de dado não equivale a ausência de efeito.

que ela não ocorreu. Essa adaptação segue a ideia de um evento inicial que produz uma consequência posterior em outra unidade, presente na literatura de efeito dominó [1], aplicada aqui à transmissão temporal de preços.

9.3 Rastreabilidade, resultados e limitações

A caracterização foi gravada em `resultados/efeitos/domino/efeito_domino.sqlite`, sem modificar os bancos anteriores. A execução pode ser feita isoladamente ou pelo pipeline completo, que executa pré-processamento, Granger e caracterização em sequência.

O banco registra o caminho e o hash SHA-256 do banco de Granger, o identificador da execução de origem, as relações recebidas e os parâmetros usados. Antes de substituir a saída anterior, o processo verifica a integridade do SQLite, a correspondência entre o resumo e as quantidades de choques, eventos classificáveis, confirmações e não confirmações, além de exigir que todo rótulo 1 tenha status `confirmado` e todo rótulo 0 tenha status `nao_confirmado`.

A Tabela 5 resume a execução documentada. Entre os 4.807 eventos classificáveis, 1.881 foram confirmados, correspondendo a 39,1%. A proporção foi semelhante no treino e no teste, com 39,0% e 39,5%, respectivamente.

Tabela 5: Resumo da caracterização atual do Efeito Dominó.

Indicador	Quantidade
Relações de Granger analisadas	62
Choques encontrados na origem	6.138
Eventos classificáveis	4.807
Efeitos confirmados	1.881
Efeitos não confirmados	2.926
Movimentos simultâneos	841
Eventos sem base observada no destino	469
Eventos sem cobertura posterior	21

Fonte: banco `resultados/efeitos/domino/efeito_domino.sqlite` da execução documentada.

Todas as 62 relações apresentaram ao menos um evento classificável e uma confirmação. Entre as confirmações, 610 ocorreram no primeiro dia útil e 449 no segundo. Ainda assim, os 1.881 registros não devem ser interpretados como ocorrências totalmente independentes: foram identificados 433 grupos nos quais mais de um choque foi associado ao mesmo produto, destino e data de resposta,

totalizando 647 registros adicionais. Antes do treinamento, será necessário definir como agrupar essas sobreposições e comparar a taxa observada com um controle formado por relações não significativas ou datas embaralhadas.

Referências

[1] Paul Swuste et al. “Domino effects in chemical factories and clusters: An historical perspective and discussion”. Em: *Process Safety and Environmental Protection* 124 (2019), pp. 18–30. DOI: 10.1016/j.psep.2019.01.015.

[2] C. W. J. Granger. “Investigating Causal Relations by Econometric Models and Cross-spectral Methods”. Em: *Econometrica* 37.3 (1969), pp. 424–438. DOI: 10.2307/1912791.

[3] Kamille Oliveira et al. “Causalidade no preço do tomate no estado do Ceará”. Em: *Contribuciones a Las Ciencias Sociales* 16.10 (2023), pp. 20877–20896. DOI: 10.55905/revconv.16n.10-132.

[4] Yoav Benjamini e Yosef Hochberg. “Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing”. Em: *Journal of the Royal Statistical Society: Series B (Methodological)* 57.1 (1995), pp. 289–300. DOI: 10.1111/j.2517-6161.1995.tb02031.x.