Departamento de Ciência da Computação – UFSJ/DCOMP

# MINERAÇÃO DE DADOS APLICADA À DINÂMICA DE PREÇOS NAS CEASAS

Pré-processamento para análise do Efeito Dominó

Autores:

Arthur Henrique Moreira Santos
Gabriel da Silva Souza
Samuel de Souza Carvalho Almeida

Ciência da Computação – UFSJ/DCOMP

São João del-Rei – MG
2026

# Sumário

**Resumo** **1**

**1 Introdução** **1**

**2 Objetivos** **2**

2.1 Perguntas de pesquisa . . . . . 2

2.2 Objetivo geral . . . . . 2

2.3 Objetivos específicos . . . . . 2

**3 Trabalhos relacionados** **3**

**4 Caracterização da base de dados** **3**

**5 Metodologia do pré-processamento** **4**

5.1 Ambiente e reprodutibilidade . . . . . 4

5.2 Seleção e consolidação das cotações . . . . . 4

5.3 Normalização dos produtos . . . . . 4

5.4 Tratamento das apresentações e unidades . . . . . 4

5.5 Conversões inferidas . . . . . 5

5.6 Exclusões e indicadores de qualidade . . . . . 5

5.7 Estrutura e validação da saída . . . . . 6

**Referências** **6**

# Resumo

Este trabalho investiga a dinâmica de preços de produtos agrícolas comercializados em diferentes Centrais de Abastecimento (CEASAs). A primeira etapa da pesquisa concentra-se no Efeito Dominó, entendido como a possibilidade de variações de preço observadas em um mercado contribuírem para antecipar variações posteriores em outro. Os dados utilizados foram coletados por um *crawler* e organizados em um banco SQLite com mais de dois milhões de cotações. Antes da análise temporal, foi desenvolvido um pré-processamento para consolidar versões da mesma cotação, normalizar produtos e apresentações, converter preços para unidades comparáveis quando existem evidências suficientes e registrar limitações sem criar valores artificiais. O processo gera um novo banco SQLite, preserva o banco bruto e mantém indicadores de qualidade, regras de conversão e possíveis *outliers*. Na última execução realizada, 2.380.608 registros brutos resultaram em 2.372.920 cotações consolidadas. Após a exclusão de 87.820 registros sem mapeamento suficiente, foram gravadas 2.285.100 cotações no banco derivado, das quais 2.080.417 compõem a camada analítica principal. O pré-processamento da base atual foi concluído; as regras de conversão inferida permanecem candidatas até a definição do período de treino.


**Palavras-chave:** CEASA; mineração de dados; séries temporais; pré-processamento; preços agrícolas; Efeito Dominó.


# 1 Introdução

As CEASAs concentram a comercialização atacadista de produtos agrícolas e produzem cotações que refletem condições de oferta, demanda, sazonalidade, logística e características regionais. Quando observados ao longo do tempo, esses registros permitem investigar se movimentos de preço permanecem locais ou se aparecem posteriormente em outros mercados.

O projeto considera três frentes de investigação: propagação de preços entre mercados, assimetria entre aumentos e reduções e períodos de elevada volatilidade. A etapa atual concentra-se na propagação de preços, denominada Efeito Dominó. As perguntas que orientam essas frentes são apresentadas na Seção de Objetivos.

Uma análise desse tipo exige séries comparáveis. Entretanto, a base contém diferenças de escrita nos produtos, múltiplas formas de apresentação, quantidades expressas em massa ou contagem, intervalos de peso, versões da mesma cotação e valores potencialmente suspeitos. Comparar diretamente os preços originais poderia confundir uma mudança de embalagem com uma variação econômica real.

Diante disso, a primeira entrega do projeto foi a construção de um fluxo de pré-processamento rastreável. Seu objetivo é produzir uma base derivada mais adequada às futuras análises temporais, sem modificar o banco bruto e sem antecipar decisões relativas aos produtos, períodos ou modelos que serão utilizados posteriormente.

O uso do termo Efeito Dominó neste projeto é uma analogia à propagação sequencial descrita em outras áreas. Na segurança de processos, por exemplo, um evento inicial pode produzir consequências sucessivas em outras unidades [1]. Neste trabalho, a propagação investigada não envolve acidentes: corresponde à possível transmissão temporal de informação entre os preços observados em mercados

distintos.

# 2 Objetivos

## 2.1 Perguntas de pesquisa

O projeto foi organizado a partir das seguintes perguntas:

1. **Efeito Dominó:** usar os preços de outras CEASAs ajuda a prever aumentos de preços em um mercado específico?
2. **Efeito Foguete e Pena:** é possível identificar e prever situações em que os preços sobem mais rápido do que caem entre diferentes CEASAs?
3. **Agrupamento de Volatilidade:** é possível prever períodos de grandes oscilações nos preços de produtos agrícolas comercializados nas CEASAs?

A etapa atual do trabalho concentra-se na primeira pergunta. As demais serão desenvolvidas posteriormente.

## 2.2 Objetivo geral

Preparar as cotações históricas das CEASAs para a futura investigação do Efeito Dominó entre entrepostos, preservando a rastreabilidade das transformações e evitando conversões sem evidência suficiente.

## 2.3 Objetivos específicos

- consolidar versões associadas à mesma cotação lógica;
- normalizar diferenças textuais sem misturar automaticamente produtos ou variedades distintas;
- interpretar unidades, embalagens, contagens e intervalos;
- calcular preços por quilograma, unidade-base ou item quando possível;
- identificar registros inadequados para a camada analítica;
- sinalizar e preservar possíveis *outliers*, mantendo-os fora da camada analítica principal sem apagar os valores originais;
- gerar um banco derivado reproduzível e validado.

# 3 Trabalhos relacionados

Swuste et al. [1] apresentam uma revisão histórica do conceito de efeito dominó em fábricas e agrupamentos da indústria química. Nesse contexto, o fenômeno é caracterizado por uma sequência na qual um evento inicial produz efeitos capazes de atingir outras unidades. Embora o domínio seja diferente, a noção de propagação espacial e sequencial contribui para delimitar a analogia empregada neste projeto. Aqui, os eventos analisados são movimentos de preço, e não acidentes industriais.

No domínio de preços agrícolas, Oliveira et al. [2] analisaram séries mensais dos tomates Longa Vida e Cajá comercializados em Fortaleza e Ibiapaba, no Ceará, entre janeiro de 2011 e dezembro de 2022. Utilizando causalidade de Granger, o estudo identificou relação bilateral para o tomate Longa Vida e relação unidirecional de Fortaleza para Ibiapaba no caso do tomate Cajá. Esse resultado demonstra a aplicação do teste à transmissão regional de preços de um produto agrícola e fornece uma referência metodológica direta para a primeira pergunta desta pesquisa.

# 4 Caracterização da base de dados

A base de origem é o arquivo `data/cotacoes.sqlite`, produzido pelo processo de coleta das cotações. O banco relaciona cotações, produtos, apresentações, entrepostos, CEASAs, coletas e proveniências. A origem das observações também permite distinguir os registros coletados diretamente daqueles provenientes do complemento PROHORT.

A execução mais recente partiu de 2.380.608 cotações. Após a seleção das coletas mais recentes e a consolidação de versões, foram obtidas 2.372.920 cotações. A exclusão de mapeamentos insuficientes resultou em 2.285.100 cotações gravadas no banco derivado. A Tabela 1 resume os principais indicadores observados nessa execução.

Tabela 1: Indicadores da execução mais recente do pré-processamento.

| **Indicador** | **Quantidade** |
|---|---|
| Cotações no banco bruto | 2.380.608 |
| Cotações consolidadas | 2.372.920 |
| Cotações excluídas por mapeamento insuficiente | 87.820 |
| Cotações gravadas no banco derivado | 2.285.100 |
| Identidades com múltiplas versões mantidas | 5.987 |
| Apresentações catalogadas | 1.941 |
| Cotações com preço comum válido | 2.081.125 |
| Cotações com preço comum por kg | 1.824.620 |
| Cotações na camada analítica principal | 2.080.417 |
| *Outliers* desconsiderados da camada principal | 708 |
| Regras de conversão inferida candidatas | 69 |
| Regras com critérios estruturais atendidos | 49 |

Fonte: resumo da execução mais recente do pré-processamento.

Essas quantidades descrevem a execução concluída para a base atual. Uma nova execução somente produzirá números diferentes se a base de origem ou os critérios configuráveis forem alterados.

# 5 Metodologia do pré-processamento

## 5.1 Ambiente e reprodutibilidade

O pré-processamento foi implementado em Python e executado em contêiner Docker. As dependências são gerenciadas pelo `uv`, enquanto o Docker Compose fornece um comando único para construção da imagem e execução do processo. O banco bruto é aberto somente para leitura, e o resultado é gravado em um novo arquivo, `data/cotacoes_preprocessadas.sqlite`.

A substituição da saída é atômica: o novo banco é construído em um arquivo temporário e somente substitui a versão anterior após a conclusão das validações. Assim, uma falha durante o processamento não sobrescreve uma saída válida nem altera a fonte original.

## 5.2 Seleção e consolidação das cotações

A identidade lógica de uma cotação representa a combinação de mercado, produto, apresentação e data, sem utilizar o preço como parte de sua definição. Uma mesma identidade pode aparecer em diferentes coletas ou possuir versões simultâneas com preços distintos.

Para cada identidade, o processo seleciona a coleta mais recente registrada na tabela de proveniências. Quando a coleta escolhida contém mais de uma versão, os preços mínimo, comum e máximo são consolidados separadamente pela mediana. Essa regra evita escolher arbitrariamente uma das versões e reduz a influência de um valor isolado. O banco derivado mantém apenas uma linha por identidade e registra a quantidade de versões e a existência de conflito.

## 5.3 Normalização dos produtos

Os nomes dos produtos recebem uma chave textual sem diferenças de caixa, acentuação, espaços ou pontuação. A descrição original e o identificador do produto continuam preservados. A normalização permite reconhecer grafias equivalentes, mas não junta automaticamente variedades ou classificações que possam apresentar comportamentos de preço diferentes.

Descrições sem conteúdo utilizável, como `*`, recebem o marcador `produto_invalido`. Esses registros permanecem identificáveis no banco, mas não entram na visão analítica principal.

## 5.4 Tratamento das apresentações e unidades

As apresentações são classificadas segundo sua dimensão: massa, volume, contagem, unidade nativa ou combinação dessas formas. A apresentação original é preservada juntamente com a regra, a fórmula, a evidência e o nível de confiança utilizados na transformação.

Quando o peso total está explícito, a conversão é classificada como `exata`. Quando existem quantidade de itens e peso individual, o peso total é calculado pela multiplicação desses valores e a conversão é `calculada`. Unidades como dúzia e cento são convertidas para 12 e 100 itens, respectivamente, mas não recebem peso em quilogramas sem evidência do peso individual.

Intervalos como `CX 25-28 KG` preservam os limites mínimo e máximo. Um valor central não é criado, pois isso introduziria uma precisão inexistente na fonte. O mesmo princípio é aplicado às apresentações ambíguas: quando não é possível determinar o denominador do preço, a conversão para R$/kg não é realizada.

Também foi tratada uma inconsistência textual específica na qual o sufixo de origem `PE` aparece concatenado à unidade de massa. Dessa forma, `Cx.20 KgPE` é interpretado como 20 kg com o sufixo PE, enquanto `Cx.23 a27KgPE` permanece como intervalo de 23 a 27 kg.

O parser também reconhece intervalos com hífen antes da unidade, como `Cx.17a18-Kg`, preserva pesos totais explícitos quando o texto contém um intervalo independente de itens e identifica contagens explícitas de unidades ou vasos mesmo quando não existe unidade estruturada na fonte.

## 5.5 Conversões inferidas

Apresentações sem peso explícito podem ser comparadas com apresentações que possuem peso declarado para a mesma chave textual de produto, forma de apresentação e origem dos dados. Uma regra somente atende aos critérios estruturais quando candidato e âncora possuem ao menos cinco registros e três datas, e quando todos os pesos explícitos observados concordam.

Os preços não são utilizados para escolher o peso inferido. Essa decisão evita aproximar artificialmente os preços entre CEASAs e produzir o padrão de propagação que a pesquisa pretende investigar. Sem uma data limite definida para a inferência, as regras são apenas registradas como candidatas.

## 5.6 Exclusões e indicadores de qualidade

Na versão atual do código, cotações que permanecem com os status `sem_unidade`, `sem_quantidade_exata` ou `ambigua` não são gravadas na tabela final. As quantidades excluídas por cada motivo são registradas em `resumo_preprocessamento`. As próprias linhas ficam disponíveis em `cotacoes_excluidas_mapeamento`, além de continuarem preservadas no banco bruto.

Preços comuns nulos, iguais a zero ou negativos são marcados como inválidos e ficam fora de `cotacoes_analiticas`. Quando a relação mínimo $\leq$ comum $\leq$ máximo não é respeitada, o preço comum tratado é mantido, mas os limites mínimo e máximo tratados ficam nulos. Essa decisão evita trocar ou ordenar automaticamente valores cuja coluna incorreta não pode ser determinada.

Os possíveis *outliers* são identificados dentro de grupos com o mesmo produto, entreposto e apresentação. Com pelo menos cinco observações, preços por kg inferiores a 0,1 vez ou superiores a 10 vezes a mediana do grupo são sinalizados. Preço comum igual a R$ 0,01 ou razão inferior a 0,01 ou superior a 20 recebe a classificação `erro_provavel`. Entre os demais casos, grupos com pelo menos cinco ocorrências suspeitas recebem `inconsistencia_recorrente`; os restantes são classificados como `extremo_isolado`.

Os valores sinalizados não são apagados nem corrigidos. Eles permanecem na tabela principal e nas visões de auditoria, mas ficam fora de `cotacoes_analiticas_principais`. Assim, não existe uma etapa de revisão manual obrigatória para que a base seja utilizada.

### 5.7 Estrutura e validação da saída

O banco derivado contém a tabela principal `cotacoes_preprocessadas`, as visões `cotacoes_analiticas` e `cotacoes_analiticas_principais`, a tabela auditável de exclusões, o catálogo de apresentações, as regras de conversão, as classificações de *outliers*, o resumo e os parâmetros da execução.

Ao final, são verificadas a integridade interna do SQLite, a unicidade das identidades, a consistência dos marcadores, a cobertura do catálogo e a igualdade entre as quantidades consolidadas, gravadas e excluídas. A validação também confere a cobertura auditável das exclusões e garante que nenhum *outlier* permaneça na camada analítica principal. Com a execução validada, o pré-processamento da base atual está concluído.

## Referências


[1] Paul Swuste et al. "Domino effects in chemical factories and clusters: An historical perspective and discussion". Em: *Process Safety and Environmental Protection* 124 (2019), pp. 18–30. DOI: 10.1016/j.psep.2019.01.015.

[2] Kamille Oliveira et al. "Causalidade no preço do tomate no estado do Ceará". Em: *Contribuciones a Las Ciencias Sociales* 16.10 (2023), pp. 20877–20896. DOI: 10.55905/revconv.16n.10-132.