Departamento de Ciência da Computação – UFSJ/DCOMP

MINERAÇÃO DE DADOS APLICADA À DINÂMICA DE PREÇOS NAS CEASAS

Pré-processamento, séries temporais e teste de Granger

Autores:

Arthur Henrique Moreira Santos
Gabriel da Silva Souza
Samuel de Souza Carvalho Almeida

Ciência da Computação – UFSJ/DCOMP

São João del-Rei – MG
2026

Sumário

Resumo **1**

1 Introdução **1**

2 Objetivos **2**

2.1 Perguntas de pesquisa 2

2.2 Objetivo geral 2

2.3 Objetivos específicos 2

3 Trabalhos relacionados **3**

4 Caracterização da base de dados **3**

5 Metodologia **3**

5.1 Visão geral do fluxo 3

5.2 Ambiente e reprodutibilidade 5

5.3 Seleção e consolidação das cotações 5

5.4 Normalização dos produtos 5

5.5 Tratamento das apresentações e unidades 5

5.6 Conversões inferidas 6

5.7 Exclusões e indicadores de qualidade 6

5.8 Estrutura e validação da saída 7

6 Construção das séries temporais **7**

7 Teste de causalidade de Granger **7**

8 Resultados atuais **8**

Referências **9**

Resumo

Este trabalho investiga a dinâmica de preços de produtos agrícolas comercializados em diferentes Centrais de Abastecimento (CEASAs). A etapa atual concentra-se no Efeito Dominó, entendido como a possibilidade de movimentos de preço observados em um entreposto contribuírem para antecipar movimentos posteriores em outro. Os dados foram coletados por um *crawler* e organizados em um banco SQLite com mais de dois milhões de cotações. O fluxo executado até o momento compreende a preservação do banco bruto, o pré-processamento das cotações, a construção de séries temporais comparáveis e o teste de causalidade de Granger. Na execução atual, 2.388.035 registros brutos resultaram em 2.295.094 cotações no banco derivado, das quais 1.833.726 possuem preço comum em R$/kg. O recorte temporal carregou 175.160 cotações e produziu 252 pares candidatos entre mercados. Dos 134 pares elegíveis, todos atenderam aos critérios de estacionariedade; foram testadas 268 direções e 62 apresentaram significância após a correção de Benjamini–Hochberg. Esses resultados são preliminares e representam evidência de precedência temporal e capacidade preditiva no sentido de Granger, não uma demonstração isolada de causalidade econômica direta.

Palavras-chave: CEASA; mineração de dados; séries temporais; pré-processamento; preços agrícolas; Efeito Dominó.

1 Introdução

As CEASAs concentram a comercialização atacadista de produtos agrícolas e produzem cotações que refletem condições de oferta, demanda, sazonalidade, logística e características regionais. Quando observados ao longo do tempo, esses registros permitem investigar se movimentos de preço permanecem locais ou se aparecem posteriormente em outros mercados.

O projeto considera três frentes de investigação: propagação de preços entre mercados, assimetria entre aumentos e reduções e períodos de elevada volatilidade. A etapa atual concentra-se na propagação de preços, denominada Efeito Dominó. As perguntas que orientam essas frentes são apresentadas na Seção de Objetivos.

Uma análise desse tipo exige séries comparáveis. Entretanto, a base contém diferenças de escrita nos produtos, múltiplas formas de apresentação, quantidades expressas em massa ou contagem, intervalos de peso, versões da mesma cotação e valores potencialmente suspeitos. Comparar diretamente os preços originais poderia confundir uma mudança de embalagem com uma variação econômica real.

Diante disso, foi construído um fluxo rastreável que parte do banco produzido pelo *crawler*, gera uma base pré-processada, organiza séries temporais comparáveis e aplica o teste de Granger. O banco bruto não é modificado e cada etapa gera uma saída derivada auditável. Até o momento, não foi realizado o treinamento de um modelo preditivo: essa fase será definida após a caracterização operacional do Efeito Dominó.

O uso do termo Efeito Dominó neste projeto é uma analogia à propagação sequencial descrita em outras áreas. Na segurança de processos, por exemplo, um evento inicial pode produzir consequências sucessivas em outras unidades [1]. Neste trabalho, a propagação investigada não envolve acidentes: corresponde à possível transmissão temporal de informação entre os preços observados em mercados

distintos.

2 Objetivos

2.1 Perguntas de pesquisa

O projeto foi organizado a partir das seguintes perguntas:

1. **Efeito Dominó:** usar os preços de outras CEASAs ajuda a prever aumentos de preços em um mercado específico?
2. **Efeito Foguete e Pena:** é possível identificar e prever situações em que os preços sobem mais rápido do que caem entre diferentes CEASAs?
3. **Agrupamento de Volatilidade:** é possível prever períodos de grandes oscilações nos preços de produtos agrícolas comercializados nas CEASAs?

A etapa atual do trabalho concentra-se na primeira pergunta. As demais serão desenvolvidas posteriormente.

2.2 Objetivo geral

Preparar e analisar as cotações históricas das CEASAs para investigar a existência de influência temporal entre entrepostos no sentido de Granger, preservando a rastreabilidade das transformações e evitando conversões sem evidência suficiente.

2.3 Objetivos específicos

- consolidar versões associadas à mesma cotação lógica;
- normalizar diferenças textuais sem misturar automaticamente produtos ou variedades distintas;
- interpretar unidades, embalagens, contagens e intervalos;
- calcular preços por quilograma, unidade-base ou item quando possível;
- identificar registros inadequados para a camada analítica;
- sinalizar e preservar possíveis *outliers*, mantendo-os fora da camada analítica principal sem apagar os valores originais;
- gerar um banco derivado reproduzível e validado;
- construir séries diárias comparáveis por produto e entreposto;
- verificar a estacionariedade das séries de retornos;
- testar a precedência temporal entre pares de entrepostos por meio da causalidade de Granger.

3 Trabalhos relacionados

Swuste et al. [1] apresentam uma revisão histórica do conceito de efeito dominó em fábricas e agrupamentos da indústria química. Nesse contexto, o fenômeno é caracterizado por uma sequência na qual um evento inicial produz efeitos capazes de atingir outras unidades. Embora o domínio seja diferente, a noção de propagação espacial e sequencial contribui para delimitar a analogia empregada neste projeto. Aqui, os eventos analisados são movimentos de preço, e não acidentes industriais.

O teste proposto por Granger [2] verifica se valores passados de uma série acrescentam informação à previsão de outra série, além da informação já contida no próprio histórico da variável prevista. Portanto, a expressão causalidade de Granger indica precedência temporal com ganho preditivo e não, isoladamente, um mecanismo econômico causal.

No domínio de preços agrícolas, Oliveira et al. [3] analisaram séries mensais dos tomates Longa Vida e Cajá comercializados em Fortaleza e Ibiapaba, no Ceará, entre janeiro de 2011 e dezembro de 2022. Utilizando causalidade de Granger, o estudo identificou relação bilateral para o tomate Longa Vida e relação unidirecional de Fortaleza para Ibiapaba no caso do tomate Cajá. Esse resultado demonstra a aplicação do teste à transmissão regional de preços de um produto agrícola e fornece uma referência metodológica direta para a primeira pergunta desta pesquisa.

4 Caracterização da base de dados

A base de origem é o arquivo `data/cotacoes.sqlite`, produzido pelo processo de coleta das cotações. O banco relaciona cotações, produtos, apresentações, entrepostos, CEASAs, coletas e proveniências. A origem das observações também permite distinguir os registros coletados diretamente daqueles provenientes do complemento PROHORT.

A execução mais recente partiu de 2.388.035 cotações. Após a seleção das coletas mais recentes e a consolidação de versões, foram obtidas 2.380.218 cotações. A exclusão de mapeamentos insuficientes resultou em 2.295.094 cotações gravadas no banco derivado. A Tabela 1 resume os principais indicadores observados nessa execução.

Essas quantidades descrevem a execução concluída para a base atual. Uma nova execução somente produzirá números diferentes se a base de origem ou os critérios configuráveis forem alterados.

5 Metodologia

5.1 Visão geral do fluxo

A Figura 1 apresenta as etapas concluídas até o momento. Cada banco derivado preserva a origem e os parâmetros de sua execução, permitindo reproduzir o caminho entre a coleta e os resultados estatísticos.

Tabela 1: Indicadores da execução mais recente do pré-processamento.

Indicador	**Quantidade**
Cotações no banco bruto	2.388.035
Cotações consolidadas	2.380.218
Cotações excluídas por mapeamento insuficiente	85.124
Cotações gravadas no banco derivado	2.295.094
Identidades com múltiplas versões mantidas	6.041
Apresentações catalogadas	1.941
Cotações com preço comum válido	2.091.042
Cotações com preço comum por kg	1.833.726
Cotações na camada analítica principal	2.090.331
Outliers desconsiderados da camada principal	711
Regras de conversão inferida aplicadas	13
Cotações com conversão inferida	3.250

Fonte: resumo da execução mais recente do pré-processamento.

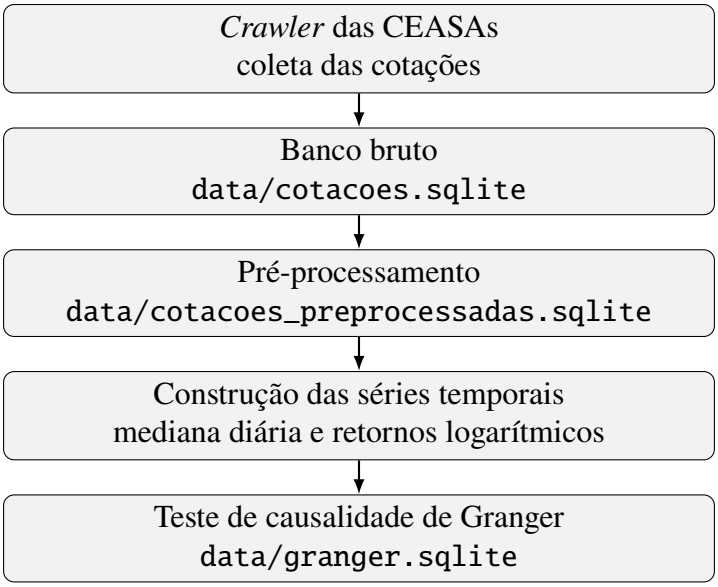


Figura 1: Fluxo metodológico executado até o teste de Granger.

5.2 Ambiente e reprodutibilidade

O pré-processamento foi implementado em Python e executado em contêiner Docker. As dependências são gerenciadas pelo `uv`, enquanto o Docker Compose fornece um comando único para construção da imagem e execução do processo. O banco bruto é aberto somente para leitura, e o resultado é gravado em um novo arquivo, `data/cotacoes_preprocessadas.sqlite`.

A substituição da saída é atômica: o novo banco é construído em um arquivo temporário e somente substitui a versão anterior após a conclusão das validações. Assim, uma falha durante o processamento não sobrescreve uma saída válida nem altera a fonte original.

5.3 Seleção e consolidação das cotações

A identidade lógica de uma cotação representa a combinação de mercado, produto, apresentação e data, sem utilizar o preço como parte de sua definição. Uma mesma identidade pode aparecer em diferentes coletas ou possuir versões simultâneas com preços distintos.

Para cada identidade, o processo seleciona a coleta mais recente registrada na tabela de proveniências. Quando a coleta escolhida contém mais de uma versão, os preços mínimo, comum e máximo são consolidados separadamente pela mediana. Essa regra evita escolher arbitrariamente uma das versões e reduz a influência de um valor isolado. O banco derivado mantém apenas uma linha por identidade e registra a quantidade de versões e a existência de conflito.

5.4 Normalização dos produtos

Os nomes dos produtos recebem uma chave textual sem diferenças de caixa, acentuação, espaços ou pontuação. A descrição original e o identificador do produto continuam preservados. A normalização permite reconhecer grafias equivalentes, mas não junta automaticamente variedades ou classificações que possam apresentar comportamentos de preço diferentes.

Descrições sem conteúdo utilizável, como `*`, recebem o marcador `produto_invalido`. Esses registros permanecem identificáveis no banco, mas não entram na visão analítica principal.

5.5 Tratamento das apresentações e unidades

As apresentações são classificadas segundo sua dimensão: massa, volume, contagem, unidade nativa ou combinação dessas formas. A apresentação original é preservada juntamente com a regra, a fórmula, a evidência e o nível de confiança utilizados na transformação.

Quando o peso total está explícito, a conversão é classificada como `exata`. Quando existem quantidade de itens e peso individual, o peso total é calculado pela multiplicação desses valores e a conversão é `calculada`. Unidades como dúzia e cento são convertidas para 12 e 100 itens, respectivamente, mas não recebem peso em quilogramas sem evidência do peso individual.

Intervalos como `CX 25-28 KG` preservam os limites mínimo e máximo. Um valor central não é criado, pois isso introduziria uma precisão inexistente na fonte. O mesmo princípio é aplicado às

apresentações ambíguas: quando não é possível determinar o denominador do preço, a conversão para R$/kg não é realizada.

Também foi tratada uma inconsistência textual específica na qual o sufixo de origem `PE` aparece concatenado à unidade de massa. Dessa forma, `Cx.20 KgPE` é interpretado como 20 kg com o sufixo PE, enquanto `Cx.23 a27KgPE` permanece como intervalo de 23 a 27 kg.

O parser também reconhece intervalos com hífen antes da unidade, como `Cx.17a18-Kg`, preserva pesos totais explícitos quando o texto contém um intervalo independente de itens e identifica contagens explícitas de unidades ou vasos mesmo quando não existe unidade estruturada na fonte.

5.6 Conversões inferidas

Apresentações sem peso explícito podem ser comparadas com apresentações que possuem peso declarado para a mesma chave textual de produto, forma de apresentação e origem dos dados. Uma regra somente atende aos critérios estruturais quando candidato e âncora possuem ao menos cinco registros e três datas, e quando todos os pesos explícitos observados concordam.

Os preços não são utilizados para escolher o peso inferido. Essa decisão evita aproximar artificialmente os preços entre CEASAs e produzir o padrão de propagação que a pesquisa pretende investigar. Para impedir que informações futuras participem da criação das regras, a data limite de inferência foi fixada em 31 de outubro de 2025, a mesma data de corte do conjunto de treino. Na execução atual, 13 regras foram aplicadas a 3.250 cotações; outras 11 regras permaneceram apenas como candidatas por não atenderem a todos os critérios definidos.

5.7 Exclusões e indicadores de qualidade

Na versão atual do código, cotações que permanecem com os status `sem_unidade`, `sem_quantidade_exata` ou `ambigua` não são gravadas na tabela final. As quantidades excluídas por cada motivo são registradas em `resumo_preprocessamento`. As próprias linhas ficam disponíveis em `cotacoes_excluidas_mapeamento`, além de continuarem preservadas no banco bruto.

Preços comuns nulos, iguais a zero ou negativos são marcados como inválidos e ficam fora de `cotacoes_analiticas`. Quando a relação mínimo $\leq$ comum $\leq$ máximo não é respeitada, o preço comum tratado é mantido, mas os limites mínimo e máximo tratados ficam nulos. Essa decisão evita trocar ou ordenar automaticamente valores cuja coluna incorreta não pode ser determinada.

Os possíveis *outliers* são identificados dentro de grupos com o mesmo produto, entreposto e apresentação. Com pelo menos cinco observações, preços por kg inferiores a 0,1 vez ou superiores a 10 vezes a mediana do grupo são sinalizados. Preço comum igual a R$ 0,01 ou razão inferior a 0,01 ou superior a 20 recebe a classificação `erro_provavel`. Entre os demais casos, grupos com pelo menos cinco ocorrências suspeitas recebem `inconsistencia_recorrente`; os restantes são classificados como `extremo_isolado`.

Os valores sinalizados não são apagados nem corrigidos. Eles permanecem na tabela principal e nas visões de auditoria, mas ficam fora de `cotacoes_analiticas_principais`. Assim, não existe uma etapa de revisão manual obrigatória para que a base seja utilizada.

5.8 Estrutura e validação da saída

O banco derivado contém a tabela principal `cotacoes_preprocessadas`, as visões `cotacoes_analiticas` e `cotacoes_analiticas_principais`, a tabela auditável de exclusões, o catálogo de apresentações, as regras de conversão, as classificações de *outliers*, o resumo e os parâmetros da execução.

Ao final, são verificadas a integridade interna do SQLite, a unicidade das identidades, a consistência dos marcadores, a cobertura do catálogo e a igualdade entre as quantidades consolidadas, gravadas e excluídas. A validação também confere a cobertura auditável das exclusões e garante que nenhum *outlier* permaneça na camada analítica principal. Com a execução validada, o pré-processamento da base atual está concluído.

6 Construção das séries temporais

O recorte atual considera 12 produtos e sete entrepostos: Recife, Grande Vitória, Curitiba, Maringá, Cascavel, Foz do Iguaçu e Londrina. Foram utilizadas cotações entre 4 de janeiro de 2022 e 31 de outubro de 2026, desde que possuam preço comum válido em R$/kg, não estejam sinalizadas como *outlier* e tenham conversão exata, calculada, padronizada ou inferida com alta confiança. O período até 31 de outubro de 2025 foi destinado à construção e ao diagnóstico das séries; o intervalo posterior foi preservado para avaliações futuras.

Quando existe mais de uma cotação para o mesmo produto, entreposto e data, utiliza-se a mediana diária do preço comum em R$/kg. Fins de semana são desconsiderados e falhas curtas podem ser preenchidas pelo último valor observado por, no máximo, três dias úteis consecutivos. Lacunas maiores permanecem abertas para não criar continuidade artificial. Em seguida, os preços são transformados em retornos logarítmicos diários:

$$r_t = \ln(P_t) - \ln(P_{t-1}), \tag{1}$$

em que P_t representa a mediana diária do preço. Essa transformação direciona a análise às variações relativas, reduzindo o efeito dos diferentes níveis de preço entre mercados.

Na execução atual, o recorte carregou 175.160 cotações, desconsiderou 320 registros de fim de semana e produziu 63.163 pontos diários observados e 8.545 pontos preenchidos. Nenhuma cotação inferida entrou nesse recorte específico.

7 Teste de causalidade de Granger

Para cada produto, foram formados todos os pares possíveis entre os sete entrepostos, totalizando 252 pares candidatos. Um par somente é elegível quando as duas séries possuem ao menos 400 dias úteis observados em comum no período de treino. Os retornos de cada série são avaliados pelos testes ADF e KPSS; o par segue para Granger apenas quando as duas séries atendem simultaneamente aos critérios de estacionariedade.

As duas direções de cada par são testadas separadamente. São avaliadas de uma a dez defasagens em uma amostra fixa, e a quantidade de defasagens é escolhida pelo Critério de Informação Bayesiano (BIC). O teste F verifica se os valores passados da série de origem acrescentam informação à previsão da série de destino. Como várias hipóteses são avaliadas, os valores p recebem correção global de Benjamini–Hochberg, com taxa de falsas descobertas de 5% [4].

Um resultado significativo é interpretado como evidência de influência temporal preditiva no sentido de Granger. Ele não prova, sozinho, que um entreposto provoque diretamente a alteração de preço no outro, pois fatores externos ou variáveis não observadas também podem explicar a relação.

8 Resultados atuais

A Tabela 2 resume a execução atual. Dos 252 pares candidatos, 134 atenderam ao mínimo de sobreposição e todos passaram pelos diagnósticos de estacionariedade. Isso produziu 268 direções testadas, das quais 80 seriam significativas sem ajuste e 62 permaneceram significativas após a correção global.

Tabela 2: Resumo dos resultados atuais do teste de Granger.

Indicador	**Quantidade**
Cotações carregadas no recorte	175.160
Pares candidatos	252
Pares elegíveis e estacionários	134
Direções testadas	268
Direções significativas sem correção	80
Direções significativas após correção FDR	62
Pares com ao menos uma direção significativa	50
Relações unidirecionais	38
Relações bidirecionais	12

Fonte: banco `data/granger.sqlite` da execução atual.

Os resultados mostram, no recorte analisado, evidências de influência temporal entre determinados entrepostos. Tomate, batata e morango concentraram, respectivamente, 14, 13 e 11 direções significativas. Curitiba e Maringá foram as origens mais frequentes entre as relações significativas, com 18 e 15 direções. Esses números são preliminares e poderão mudar caso sejam alterados o período, os produtos, os mercados ou a definição operacional do Efeito Dominó.

Até esta etapa, o trabalho demonstrou a existência de relações preditivas no sentido de Granger dentro do recorte estudado. O treinamento de modelos ainda não foi realizado. O próximo passo será definir formalmente o que constitui um evento de Efeito Dominó para então construir os alvos e atributos usados nessa fase posterior.

Referências

[1] Paul Swuste et al. “Domino effects in chemical factories and clusters: An historical perspective and discussion”. Em: *Process Safety and Environmental Protection* 124 (2019), pp. 18–30. DOI: 10.1016/j.psep.2019.01.015.

[2] C. W. J. Granger. “Investigating Causal Relations by Econometric Models and Cross-spectral Methods”. Em: *Econometrica* 37.3 (1969), pp. 424–438. DOI: 10.2307/1912791.

[3] Kamille Oliveira et al. “Causalidade no preço do tomate no estado do Ceará”. Em: *Contribuciones a Las Ciencias Sociales* 16.10 (2023), pp. 20877–20896. DOI: 10.55905/revconv.16n.10-132.

[4] Yoav Benjamini e Yosef Hochberg. “Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing”. Em: *Journal of the Royal Statistical Society: Series B (Methodological)* 57.1 (1995), pp. 289–300. DOI: 10.1111/j.2517-6161.1995.tb02031.x.